

Экзаменационная программа по курсу «Информационный поиск» за осенний семестр 2025 года.

1. Основные понятия информационного поиска: документ, слово, термин, запрос, релевантность, полнота и точность. Булевский поиск. Организация индекса для булевского поиска, выполнение запросов. Достоинства и недостатки булевой модели.
2. Лингвистика. Рационализм и эмпиризм в изучении языка. Статистическая лингвистика. Основные задачи статистической лингвистики. Законы Ципфа.
3. Выбор единицы индексирования (документа). Предварительная обработка документов, разбиение на слова, выделение терминов, нормализация, стоп-словарь. Характерные особенности текстов, написанных на естественных языках: омономия, компаунды, морфология. Основные подходы к морфологической обработке.
4. Коллокации, методы статистического поиска коллокаций.
5. Структура поискового индекса, координатные блоки, выполнение поисковых запросов. Методы ускорения выполнения многословных поисковых запросов. Виды индекса для цитатного поиска.
6. Организация словаря терминов, основные структуры данных. Выполнение запросов с метасимволами, исправление ошибок в запросах. Расстояние Левенштейна, фонетическая близость.
7. Построение индекса, основные методы сортировки и слияния координатной информации.
8. Сжатие поискового индекса. Статистические характеристики словаря терминов и координатных блоков. Сжатие словаря и координатных блоков.
9. Сжатие поискового индекса. Коды Голомба. Методы сжатия семейств Simple.
10. Ранжирование документов. Разбиение документов на зоны, отличие зон от полей метаинформации, использование информации о зонах для вычисления релевантности. Организация индекса с учётом информации о зонах.
11. Ранжирование документов, учёт количества терминов в документе и в массиве документов. Ранжирование tf-idf, его достоинства и недостатки. Модификации tf-idf.
12. Модель векторного пространства, мера близости двух документов. Ранжирование документов в векторном пространстве, выполнение поискового запроса. Эвристики, позволяющие сократить время выполнения запроса. Достоинства и недостатки модели.
13. Построение n-грамм, их применение. Разреженность, сглаживание.

14. Выкачка документов из сети Интернет, архитектура «паука». Требования и рекомендации к поведению роботов-«пауков». Технические детали реализации.