Урок №2

Поисковый робот

на которой расскажут, что такое поисковый робот, как обкачивать веб, как есть подводные камни и про robots.txt тоже расскажут.

04 октября 2023 года

Антон Кухтичев

Содержание занятия

1. URL, URN, URI
2. Протокол HTTP
3. Поисковый робот
4. Домашнее задание;

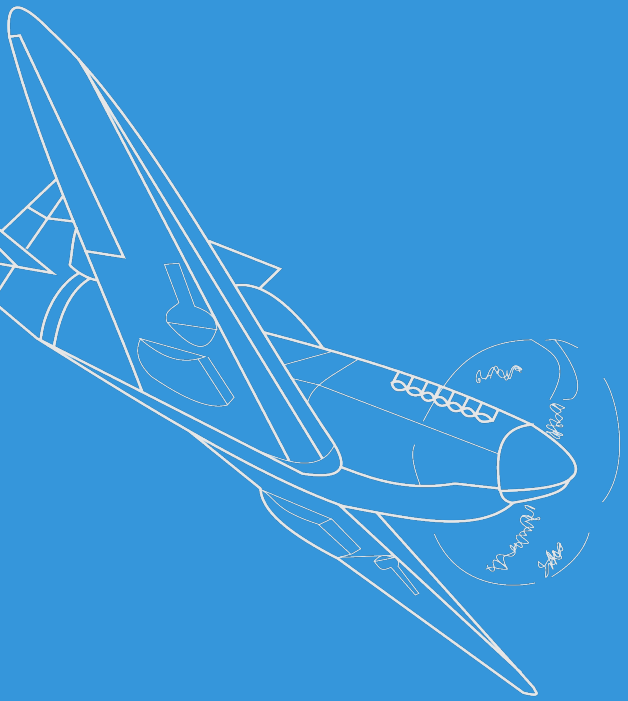

Документы

Документы

Документы могут быть:

- Статические
    - Это файлы на дисках сервера;
    - Как правило, обладают постоянным адресом.
- Динамические
    - Создаются на каждый запрос;
    - Содержимое зависит от времени и пользователя;
    - Адрес может быть постоянным или меняться.

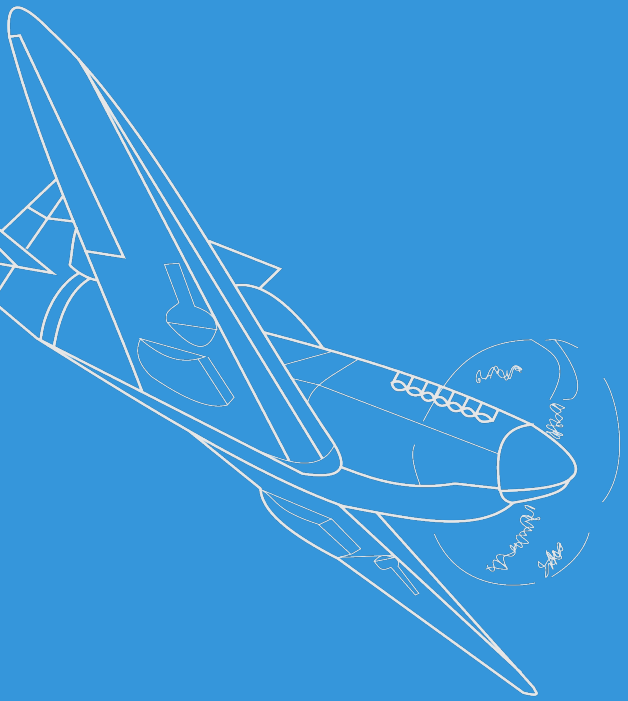

URI, URL, URN

Определения

- **URI** — Uniform Resource Identifier (унифицированный идентификатор ресурса);
- **URL** — Uniform Resource Locator (унифицированный локатор/указатель ресурса);
- **URN** — Uniform Resource Name (унифицированное имя ресурса).

URI является либо URL, либо URN, либо одновременно обоими.

URN — uniform resource name

`urn:<NID>:<NSS>`

- `<NID>` — идентификатор пространства имён;
- `<NSS>` — строка из определённого пространства имён.

Пример:

- `urn:isbn:5170224575` — URN книги, идентифицируемой номером ISBN;

URL — uniform resource locator

`<схема>://[[<логин>[:<пароль>]@]<хост>[:<порт>]][/<URL-путь>][?<параметры>][#<якорь>]`

`http://server.org:8080/path/doc.html?a=1&b=2#part1`

- `http` — протокол;
- `server.org` — DNS имя сервера (может указываться ip-адрес машины);
- `8080` — TCP порт;
- `/path/doc.html` — путь к файлу;
- `a=1&b=2` — параметры запроса;
- `part1` — якорь, положение на странице.

Абсолютные и относительные URL

- `http://server.org/1.html` — абсолютный;
- `//server.org/1.html` — абсолютный (schemeless);
- `/another/page.html?a=1` — относительный (в пределах домена);
- `pictures/cat.png` — относительный (от URL текущего документа);
- `?a=1&b=2` — относительный (от URL текущего документа);
- `#part2` — относительный (в пределах текущего документа);

Правила разрешения URL

`https://site.com/path/page.html` — основной документ

- `http://wikipedia.org` = `http://wikipedia.org`
- `//cdn.org/jquery.js` = `https://cdn.org/jquery.js`
- `/admin/index.html` = `https://site.com/admin/index.html`
- `another.html` = `https://site.com/path/another.html`
- `?full=1` = `https://site.com/path/page.html?full=1`
- `#chapter2` = `https://site.com/path/page.html#chaprer2`

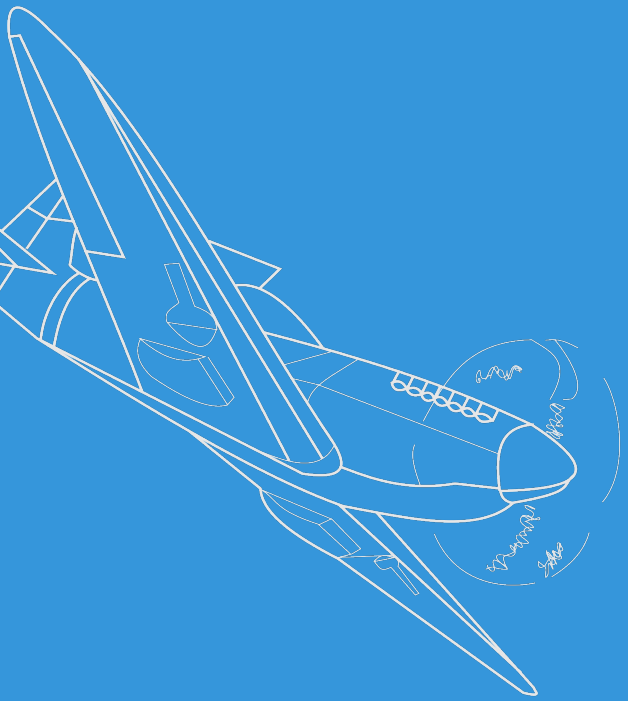

HTTP-протокол

Особенности, методы, версии, заголовки.

Как задачи решает HTTP?

- Передача документов;
- Передача мета-информации;
- Авторизация;
- Поддержка сессий;
- Кеширование документов;
- Согласование содержимого (negotiation);
- Управление соединением.

Как происходит HTTP запрос?

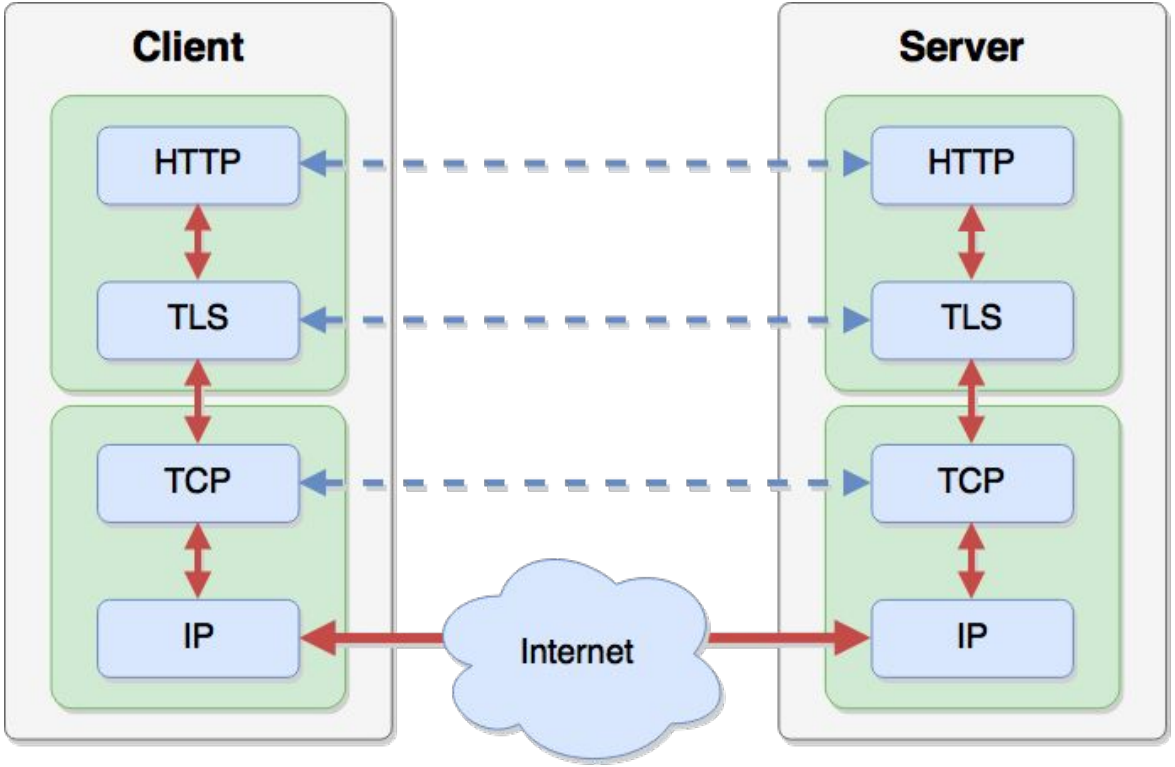

Ключевые особенности HTTP

- Работает поверх TCP/TLS;
- Протокол запрос-ответ;
- Не поддерживает состояние (соединение) — stateless;
- Текстовый протокол;
- Расширяемый протокол.

HTTP запрос состоит из

- строка запроса:
  - метод,
  - URL документа,
  - версия.
- заголовки;
- тело запроса;

HTTP/1.0 запрос


```
GET http://www.ru/robots.txt HTTP/1.0
Accept: text/html, text/plain
User-Agent: telnet/hands
If-Modified-Since: Fri, 24 Jul 2015 22:53:05 GMT
```

Перевод строки — `\r\n`

HTTP/1.1 запрос


```
GET /robots.txt HTTP/1.1
Accept: text/html,application/xhtml+xml
Accept-Encoding: gzip, deflate
Cache-Control: max-age=0
Connection: keep-alive
Host: www.ru
User-Agent: Mozilla/5.0 Gecko/20100101 Firefox/39.0
```

HTTP/1.1 ответ


```
HTTP/1.1 404 Not Found
Server: nginx/1.5.7
Date: Sat, 25 Jul 2015 09:58:17 GMT
Content-Type: text/html; charset=iso-8859-1
Connection: close

<!DOCTYPE HTML PUBLIC "-//IETF//DTD HTML 2.0//EN">
<HTML><HEAD>...
```

Методы HTTP-запроса

- `GET` — получение документа;
- `HEAD` — получение только заголовков;
- `POST` — отправка данных на сервер;
- `PUT` — отправка документа на сервер;
- `DELETE` — удаление документа;
- `CONNECT`, `TRACE`, `OPTIONS` — используются редко;
- `COPY`, `MOVE`, `MKCOL` — расширения WebDAV.

HTTP-коды ответов

- `1xx` — информационные;
- `2xx` — успешное выполнение;
- `3xx` — перенаправления;
- `4xx` — ошибка на стороне клиента;
- `5xx` — ошибка на стороне сервера.

HTTP-коды ответов (1)

`200 OK` — запрос успешно выполнен;

`204 No Content` — запрос успешно выполнен, но документ пуст;

`301 Moved Permanently` — документ сменил URL;

`302 Found` — повторить запрос по другому URL;

`304 Not Modified` — документ не изменился, использовать кеш.

HTTP-коды ответов (2)

`400 Bad Request` — неправильный синтаксис запроса;

`401 Unauthorized` — требуется авторизация;

`403 Forbidden Moved Permanently` — нет доступа (неверная авторизация);

`404 Not Found` — документ не найден;

`418 I’m a teapot`

`500 Internal Server Error` — неожиданная ошибка сервера;

`502 Bad Gateway` — проксируемый сервер отвечает с ошибкой;

`504 Gateway Timeout` — проксируемый сервер не отвечает;

Заголовки HTTP (общие)

Для управления соединением и форматом сообщения (документа):

- `Content-Type` — mime-тип документа;
- `Content-Length` — длина сообщения;
- `Content-Encoding` — кодирование документа, например, gzip-сжатие;
- `Transfer-Encoding` — формат передачи, например, chunked;
- `Connection` — управление соединением;
- `Upgrade` — смена протокола.

Заголовки HTTP-запросов

- `Authorization` — авторизация, чаще всего логин/пароль;
- `Cookie` — передача состояния (сессии) на сервер;
- `Referer` — URL предыдущего документа, контекст запроса;
- `User-Agent` — описание web-клиента, версия браузера;
- `If-Modified-Since` — условный GET запрос;
- `Accept-*` — согласование (negotiation) содержимого.

Заголовки HTTP-ответов

- `Location` — новый URL документа при перенаправлениях (коды 301, 302);
- `Set-Cookie` — установка состояния (сессии) в браузере;
- `Last-Modified` — дата последнего изменения документа;
- `Date` — Дата на сервере, для согласования кешей;
- `Server` — описание web-сервера, название и версия.

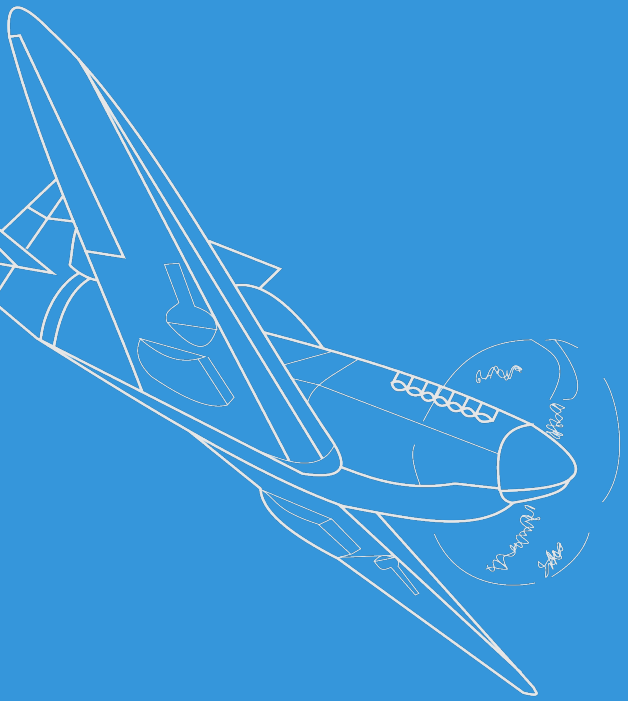

Поисковый робот

Веб без поиска

- Без поиска сложно найти нужный контент,
- Без поиска нет стимула создавать новый контент,
  - Зачем что-то публиковать, если никто не сможет прочитать?
  - Зачем что-то публиковать, если нельзя заработать на рекламе?
- Кто-то должен платить за веб,
  - Сервера, инфраструктура веб, создание контента.

Какого размера веб?

- Сложности
  - Веб на самом деле бесконечный
    - Динамический контент
  - Статический веб содержит синтаксическое дублирование, в основном, зеркала (30%)
  - Некоторые сервера редко или плохо доступны
- Кого это заботит?
  - Медиа, и соответственно, пользователей
  - Архитектуру поисковой системы
  - Алгоритмы обкачки, влияние на полноту

Новое определение

- Статический индексируемый веб - это есть индекс поисковой системы
- Различные поисковые системы имеют различные характеристики
- Различные поисковые системы индексируют различные части одного и того же URL:
  - frames, meta-keywords, document restrictions, document extensions, ...

Основные задачи поискового робота

- Изначально имеет набор известных URL;
- Скачать и распарсить страницы с них:
  - Извлечь ссылки со страницы;
  - Добавить ссылки в очередь на выкачку;
- Скачать все URL из очереди и повторить цикл.

Всё ли так просто?

- Обычные страницы тоже доставляют неприятности
  - Скорость доступа/Ширина канала до удалённых серверов различаются
  - Все сайты отличаются по своей структуре
    - Насколько глубоко робот должен обходить сайт?
  - Сайты-зеркала и дубликаты страниц
- Вежливость - не делать запросы слишком часто

Первоначальный анализ сайта

- Проходимся по нескольким страницам сайта прямо в браузере
- Пытаемся определить:
  - Есть ли редирект
  - Что возникает при “человеческом поведении”

Что любой робот должен сделать

- Быть вежливым: соблюдать явные или неявные соглашения
  - Обходить только разрешённые страницы
  - Соблюдать robots.txt
- Быть умным: устойчивость к ловушкам (spider traps) и некорректному и зловредному поведению веб-серверов

Что любой робот должен бы сделать (1)

- Поддерживать выполнение распределённых операций: иметь возможность запускаться на нескольких машинах;
- Быть масштабируемым: добавление серверов ведёт к увеличению производительности
- Производительность/эффективность: использовать все ресурсы железа и сети

Что любой робот должен бы сделать (2)

- Скачивать в первую очередь “качественные” страницы
- Постоянное обновление: скачивать свежие копии ранее скаченных страниц
- Расширяемость: поддерживать новые форматы и протоколы

Очередь URL’ов (URL frontier)

- Может содержать множество страниц с одного хоста;
- Не должна пытаться скачать их все в одно и то же время;
- Должна по возможности загружать все потоки на выкачку.

Правила вежливости

- Явные правила: веб-мастер сам определяет, какие части сайта надо обойти
  - robots.txt
- Неявные правила: даже без указаний от веб-мастеров избегать выполнения частых запросов

robots.txt (1)

- Протокол для работы робота, ограничивающий доступ к сайту, разработан в 1994 году;
- http://www.robotstxt.org/
- Сайт определяет, что не надо качать
  - robots.txt
  - <meta>

robots.txt (2)

```
User-agent: *
Allow: /article*
Disallow: /auth*
Clean-param: s /forum/showthread.php
Crawl-delay: 30
Sitemap: https://solo.nabiraem.ru/sitemap.xml
```

robots.txt (3)

Какие из этих документов мы можем скачать?

- http://site.ru/
- http://site.ru/auth/
- http://site.ru/auth/article/
- http://site.ru/article/
- http://site.ru/post/

```
User-agent: *
Allow: /article*
Disallow: /auth*
```

robots.txt (4)

Какие из этих документов мы можем скачать?

- http://site.ru/
- ~~http://site.ru/auth/~~
- ~~http://site.ru/auth/article/~~
- http://site.ru/article/
- http://site.ru/post/

```
User-agent: *
Allow: /article*
Disallow: /auth*
```

Примеры robots.txt

- https://solo.nabiraem.ru/robots.txt (любит всех)
- https://music.yandex.ru/robots.txt (очистка параметров)
- https://lenta.ru/robots.txt (эталон)
- http://tamqui.com/robots.txt (не любит майл)
- https://directmobile.ru/robots.txt (вообще никого не любит)
- https://tnt-online.ru/robots.txt (delay)

Выполнение шагов при выкачки

- Выбрать URL из очереди
- Скачать документ с этого URL
- Распарсить документ
  - Извлечь ссылки на другие документы
- Проверить, что такой документ уже есть в базе
  - Если нет, то добавить в индекс
- Для каждой извлечённой ссылки
- Убедиться, что она проходит различные фильтры
- Проверить, что её ещё нет в очереди (избегать дублирование ссылок)

Основная архитектура робота

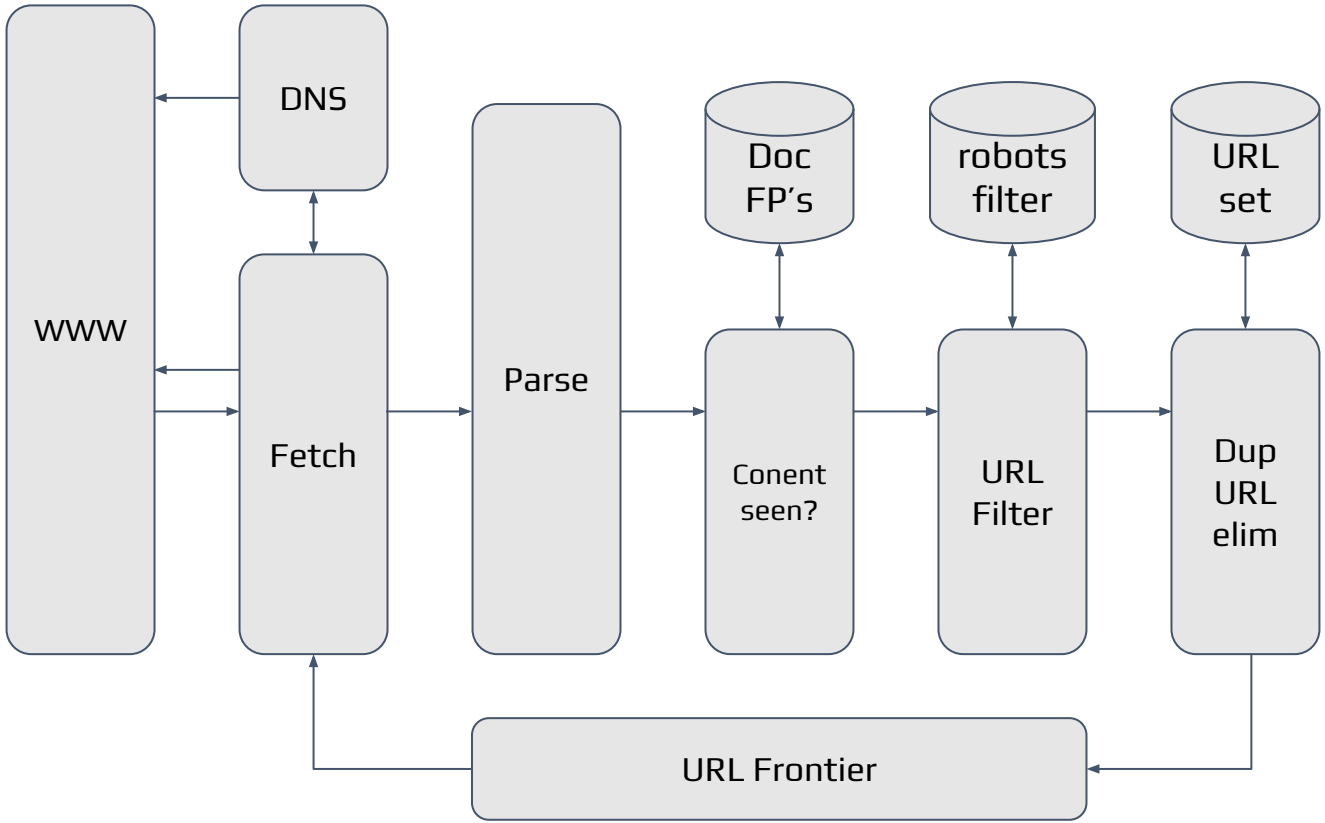

DNS (Domain Name Service)

- Сервис получения данных о хосте в интернете
  - для данного URL получить IP адрес (resolving);
  - Сервер предоставляет распределённым набором серверов, время запроса (lookup latency) может быть большим (больше секунды!)

Схема работы DNS

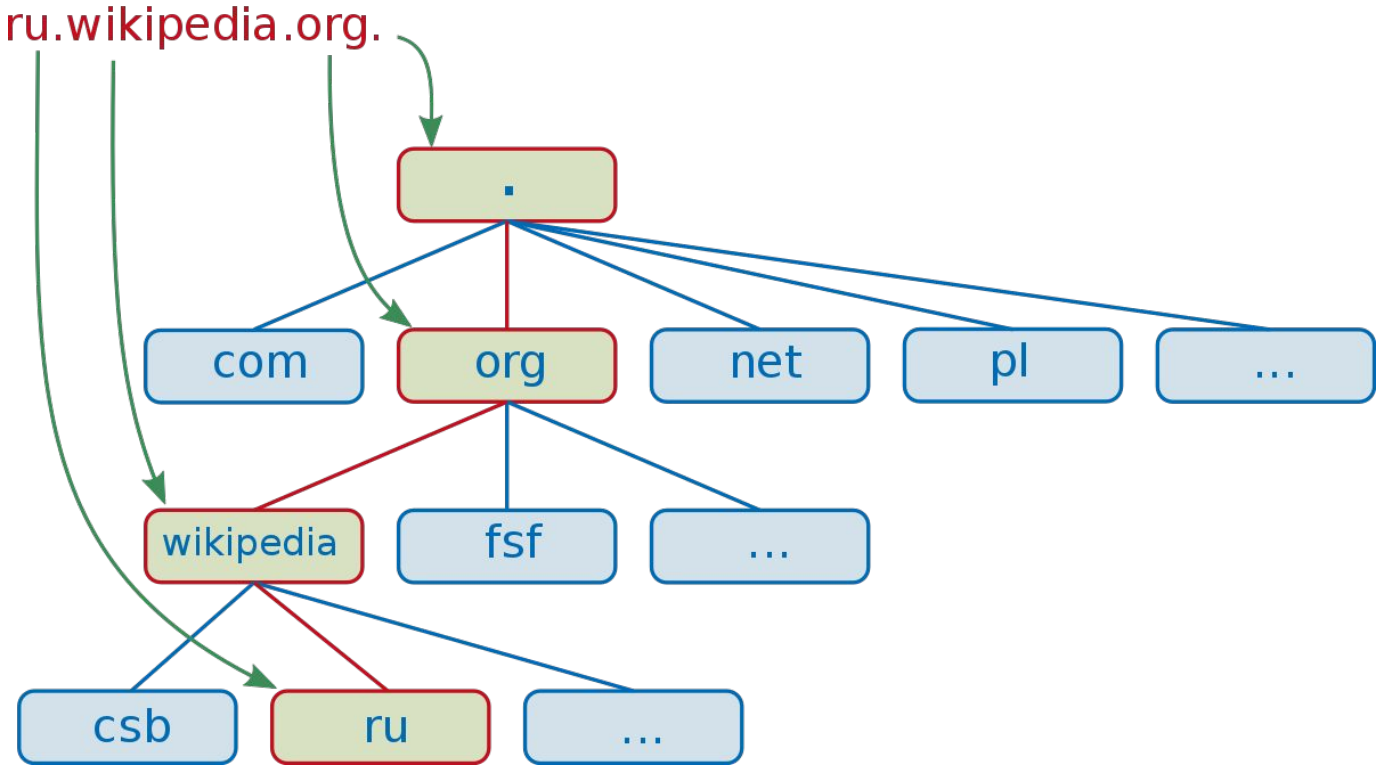

Схема работы DNS (2)

- Зачем несколько адресов?
  - Балансировка нагрузки
  - Failover
  - GeoDNS
    - IPv6 подходит лучше

Схема работы DNS (3)

- PTR-записи
  - позволяют сделать резолвинг наоборот
  - используются фаерволами, netstat и … админами!

```
$ host 217.69.135.248
248.135.69.217.in-addr.arpa domain name pointer
reco-vklive-recommend3.g.smailru.net.
```

Парсинг: нормализация URL

- При парсинге документа часть ссылок являются относительными URL;
- Во время парсинга URL’ы должны нормализоваться

Определение кодировки

- Правильней всего следовать популярным браузерам
- Не пытаемся быть умнее браузера

1. HTML: Type-Content?
2. HTML: Meta?
3. UTF-8?

Sitemaps

- Sitemaps содержат списки URL’ов и информацию про эти URL’ы
  - Например, время модификацию и частоту обновления
- Генерируются на стороне сервера
- Дают роботам подсказку, как часто обкачивать ту или иную страницу

Sitemap. Формат

URL: https://www.bfm.ru/sitemap_main.xml

```
<?xml version="1.0" encoding="UTF-8"?>
<url>
    <loc>https://www.bfm.ru/</loc>
    <lastmod>2021-09-23T14:34:36+03:00</lastmod>
    <changefreq>hourly</changefreq>
    <priority>1.0</priority>
</url>
...
```

Sitemap: примеры

- https://music.yandex.ru/sitemap-new.xml
- http://toshcorp.ru/sitemap.xml
- https://www.bfm.ru/sitemap.xml

Что кроме sitemap?

- http://apple.com/ru/sitemap
- https://www.bfm.ru/news.rss?container_breaking=8
- SEO

Хранение документов

- Требования для системы хранения документов
  - Random access
    - Доступ к документу на основе его URL’а,
    - Обычно используется hash от URL.
  - Большие файлы
    - Не надо хранить и открывать кучу файлов,
    - Уменьшает seek time.
  - Сжатие
    - Снижает требования по месту на дисках и увеличивает эффективность доступа
    - Текст сильно избыточен
    - Соседние документы часто похожи
  - Обновление
    - Иметь возможность добавлять и обновлять новый контент

Хранение документов

APACHE HBASE

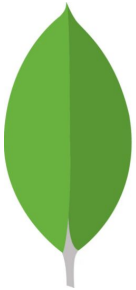

mongoDB

Couchbase

AEROSPIKE

Хранение документов

Используется для сканирования и bulk-load:

- 4 Pb, 150MM ключей,
- daily: 1MM, 15 Tb

AEROSPIKE

Используется как KV для вспомогательных нужд.

Что же делать?

- Райан Митчелл “Современный скрапинг веб-сайтов с помощью Python”;
- Про Scrapy на Python;
- Так же есть Selenium, Phantomjs, puppeteer позволяющие выполнять js;
-

Домашнее задание №2

1. Написать обкачку документов и сохранить их в базе данных
2. При сохранении документов нужно только необходимый текст (удалять навигационную обвязку и т.д.)
3. Подготовить отчёт

Рекомендуемая литература

Введение в информационный поиск | Маннинг Кристофер Д., Шютце Хайнрих

Для саморазвития (опционально)

Чтобы не набирать двумя пальчиками

Спасибо за внимание!

Антон Кухтичев

a.kukhtichev@mail.ru

@toshunster