

Урок №2

Лингвистика

на которой расскажут про лингвистику

Содержание занятия

1. Что такое лингвистика
2. История лингвистики
3. Разделы лингвистики
4. Подходы к языку
5. Морфология
6. Корпусная лингвистика
7. Закон Ципфа
8. Основы обработки текста



Что такое лингвистика?

Что такое лингвистика



Лингвистика (языкознание, языковедение; от лат. lingua — язык) — наука, изучающая языки. Это наука о естественном человеческом языке вообще и обо всех языках мира как индивидуальных его представителях.

Задачи лингвистики



- Как именно люди говорят?
- Как связаны человеческие фразы с окружающим миром?



Пра-пра-лингвисты – кто они?

- **Индия**
 - Панини (IV в. до н. э.)
 - Яска (IV в. до н. э.)



Пра-пра-лингвисты – кто они?

- **Китай**
 - Сю Шэнь (I в. н. э.)



Пра-пра-лингвисты – кто они?

- **Греция**
 - Аристарх (II в. до н. э.)
 - Дионисий Фракийский (II в. до н. э.)
 - Аполлоний Дискол (II в. до н. э.)



Пра-пра-лингвисты – кто они?

- **Рим**
 - Марк Теренций Варрон (I в. до н. э.)
 - Донат (III—IV в. н. э.)
 - Присциан (VI в. н. э.)



Пра-пра-лингвисты – кто они?

- **Аравия**
 - Сибавейхи (VII в. н. э.)
 - Ибн Джинни (конец X — начало XI в.)



Средние века и Новое время

- Грамматика Пор-Рояля
- «Идеальный» язык
- Вильгельм фон Гумбольдт (1767—1835)

- Фердинанд де Соссюр
 - «Курс общей лингвистики» (1916)
 - Язык vs речь
 - Структурная лингвистика



- Ноам Хомский
 - «Синтаксические структуры» (1957)
 - Грамматические принципы, лежащие в основе языков, являются врождёнными и неизменными



Чем занимаются лингвисты?




- Общая лингвистика
- Историческая лингвистика
- Лингвистическая типология
- Социолингвистика
- Диалектология
- Лексикография
- Психолингвистика
- Математическая лингвистика


Чем занимаются лингвисты?




- Общая лингвистика
 - Фонетика
 - Фонология
 - Морфология
 - Синтаксис
 - Семантика
 - Прагматика



- Звуки речи
 - с точки зрения его создания
 - как колебание воздуха
 - как объект восприятия



- Звуки, составляющие речь
- Фонема – минимальная
смыслоразличительная единица языка
- Слог
- Транскрипция






- Внутренняя структура отдельных слов
 - Словообразование (лексическая морфология)
 - Словоизменение
- Морфемы



- Структура предложений и связи между словами



Неоднозначность синтаксического разбора




- Time flies like an arrow.
- Души прекрасные порывы.
- Эти типы стали есть в цехе.

- Значение отдельных слов и текстов



- Использование языка в различных ситуациях



Историческая лингвистика



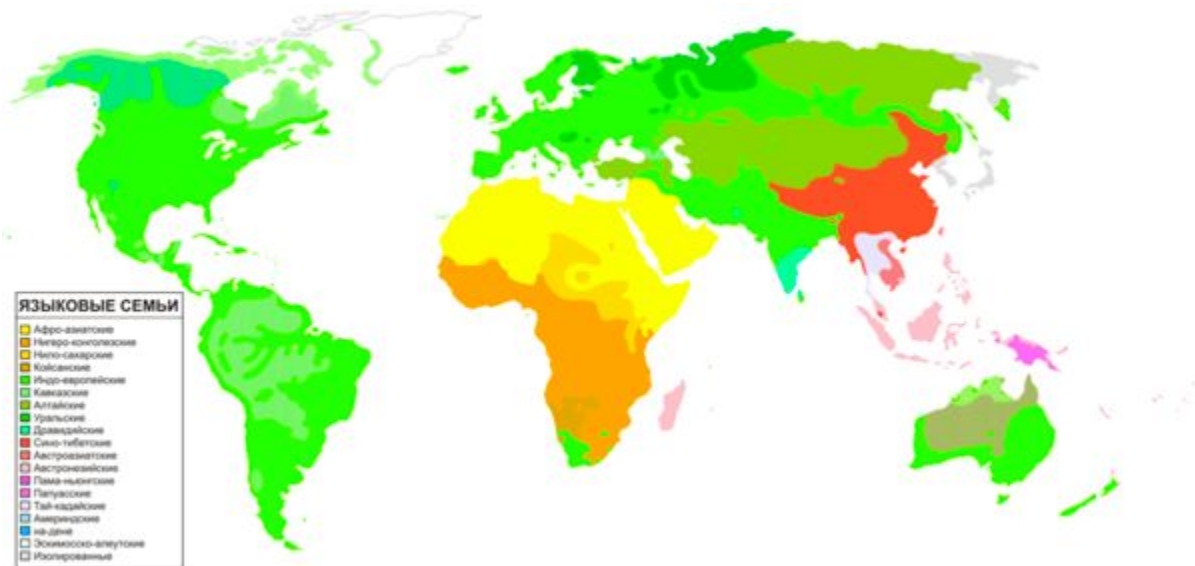
- История
- Сравнение

Spanish	English
constitución	constitution
revolución	revolution
investigación	?

- Диахрония/синхрония



- Сравнение языков, выделение характерных признаков



- Связь между языком и социальными условиями





- ПОЛНЫЙ
ЦЕРКОВНО-СЛАВЯНСКИЙ
СЛОВАРЬ

[illegible]

„По мнению и друзьям, что лучше — лучше
 играть влюбленным дуем и что симпатичней
 играть счастливо дуем, потому что приятно
 мне бы симпатичней всего с симпатичным дуем“.
 (Байбл).

„Данъ изъясненіе означенъ отъ старому нѣтъ
мѣсто изъясне доказательствомъ до нѣрѣ само. И
не ясно далъ себѣ изъясне пріемъ изъясненіа и по-
ясненіа, что нѣрѣ ясно изъясне изъясненіа въ изъяс-
неніахъ". (Вѣдѣ).


2) для преподавателей русск. и и.-слав. языки во всех высших и средних учебных заведениях; 3) для преподавателей научных русских языков, древностей, филологии, филологических дисциплин в области истории и этимологии родного языка и эт. и. работами; 4) для мастеров церкви, как совершенных богоблуждающих, законоучителей, преподавателей и миссионеров; 5) для всех, желающих иметь сведения о соотношении-различии отношения к языку матери-церкви, так и к родному слою и его современному состоянию и историческим судьбам.

Священник мѣгистръ Григорій Дьяченко

(бывший преподаватель русского языка и словесности).

Всего слов объяснено около 30.000.

- Связь языка, мышления и сознания





В узком смысле – теория порождающих грамматик

- Порождающая грамматика (generative grammar)

В широком смысле

- Количественная лингвистика
- Статистическая лингвистика
- Прикладная лингвистика

- Анализ древних языков
- Снятие омонимии
- Машинный перевод





- Рационалистический
 - Значительная часть знаний заложена внутри человека (например, наследуется) и не порождается из ощущений.
- Эмпирический
 - Человеческий мозг имеет некие способности к обобщению.
 - На основе этих общих способностей дети усваивают язык на примерах.



- Порождающая грамматика языка.
 - Любая корректная фраза порождается этой грамматикой, некорректная – нет.
- Больше интереса к «внутреннему языку», все его проявления снаружи – косвенные
- Важна интуиция носителей языка.
- Маргинальный аналог в ИИ: максимальное количество ручных правил, заложенных внутрь системы.



- Простая общая языковая модель.
- Параметры модели настраиваются на основе выбранного корпуса.
 - Статистика
 - Распознавание закономерностей
 - Машинное обучение
- Внимание сосредоточено именно на внешних проявлениях языка.



- Комбинация обоих подходов.
- До какой-то степени детализации идти рационально.
- Но когда деталей становится слишком много, применять эмпиризм.
- Пороги и подобные значения настраивать автоматически.



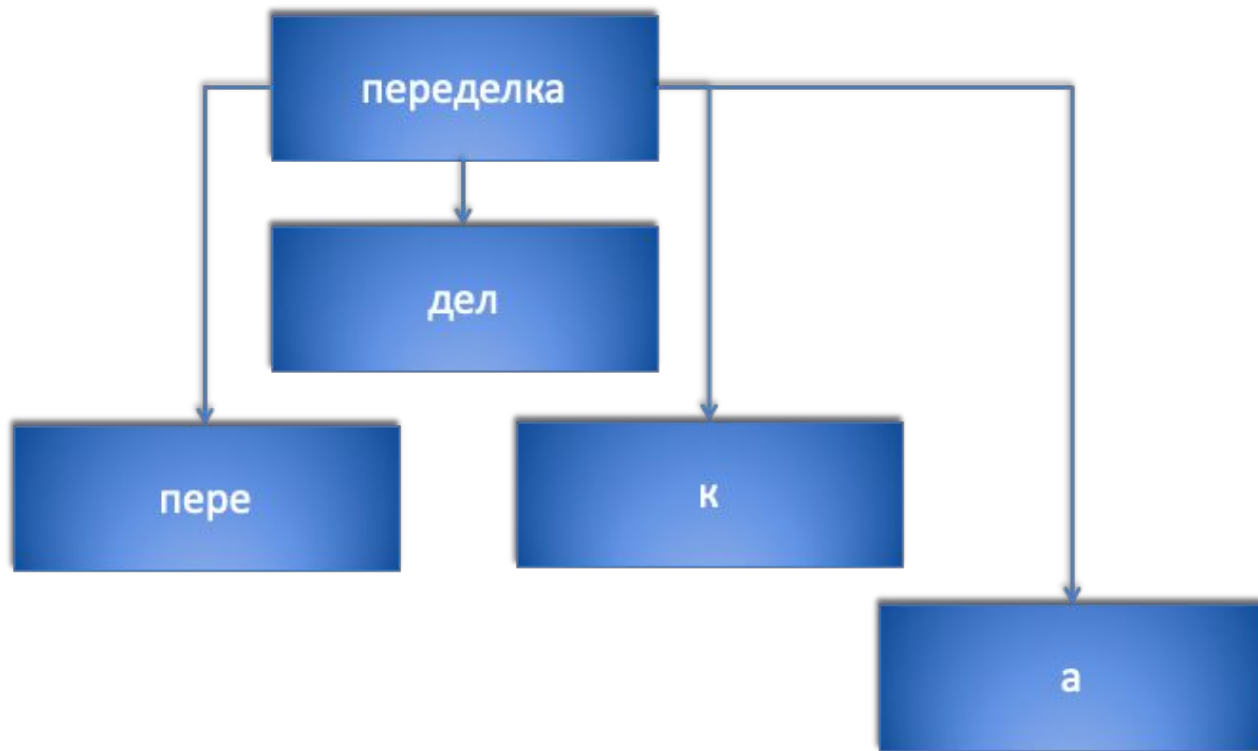
«Морфология есть часть лингвистики, занимающаяся словом во всех его релевантных аспектах» [Мельчук 1997]

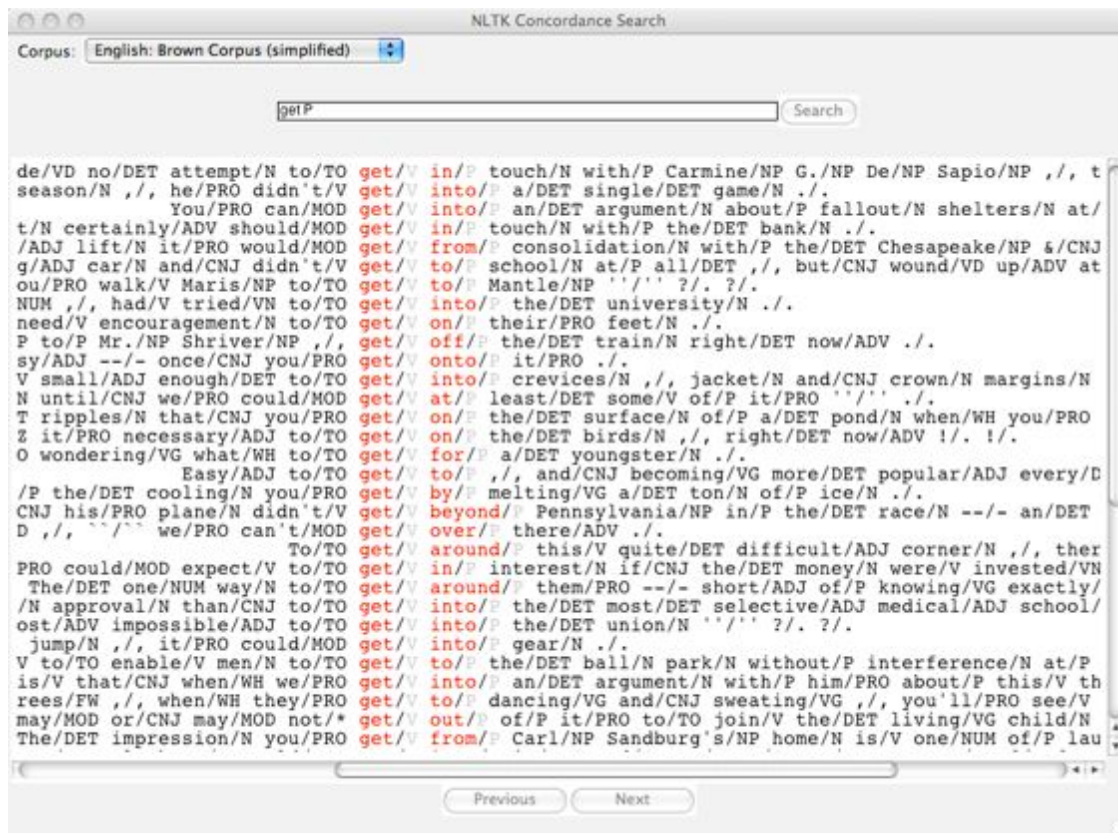



«Морфология есть часть лингвистики, занимающаяся словом во всех его релевантных аспектах» [Мельчук 1997]

Предмет морфологии - описание свойств слова и его (значащих) частей









Закон Ципфа

Закон Ципфа



Частота слова обратно пропорциональна его положению в
отсортированном по частотности списке слов

или существует такая константа k , что

$$f \cdot r = k$$


Закон Ципфа для Тома Сойера



Word	Freq. (f)	Rank (r)	$f \cdot r$
the	3332	1	3332
and	2972	2	5944
a	1775	3	5235
he	877	10	8770
but	410	20	8400
be	294	30	8820
there	222	40	8880
one	172	50	8600
about	158	60	9480
more	138	70	9660
never	124	80	9920
Oh	116	90	10440
two	104	100	10400

Word	Freq. (f)	Rank (r)	$f \cdot r$
turned	51	200	10200
you'll	30	300	9000
name	21	400	8400
comes	16	500	8000
group	13	600	7800
lead	11	700	7700
friends	10	800	8000
begin	9	900	8100
family	8	1000	8000
brushed	4	2000	8000
sins	2	3000	6000
Could	2	4000	8000
Applausive	1	8000	8000

Закон Ципфа, Brown Corpus



Поправки Мандельброта



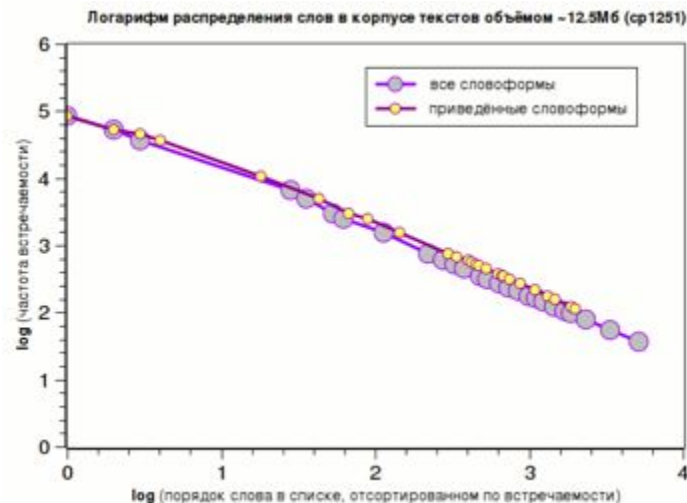
- Закон Ципфа одинаков для всех слов, но корректно предсказывает только «средние» термины.
- Он ошибается в низкочастотной и высокочастотных частях словаря
- Более точная формула:

$$f = P(r + \rho)^{-B} \quad \text{or} \quad \log f = \log P - B \log(r + \rho)$$

Главный вывод



- Частотность слов не описывается нормальным распределением
- Лучше подходит гиперболическое распределение
 - Степенной закон





- Количество смыслов у слова:
 - Слушающий: один смысл – одно слово
 - Говорящий: больше смыслов у одного слова (уменьшает количество запоминаемых слов)
- Количество смыслов m подчиняется закону:

$$m \propto \sqrt{f}$$

Другие законы Ципфа



- Количество строк или страниц текста между вхождениями одного и того же слова
- Если F – частота интервала и I – размер интервала, то: $F \propto I^{-p}$
- p колеблется от 1 до 1,3.
- То есть, одинаковые слова чаще всего встречаются рядом.

Другие законы Ципфа



- Обратная зависимость между частотностью слова и его длиной

Важность законов Ципфа




- Если сгенерировать текст случайно, то этот текст будет удовлетворять закону Ципфа

- Вероятность слова длины n для английского алфавита:

$$\left(\frac{26}{27}\right)^n \frac{1}{27}$$

- С этой точки зрения их важность для описания естественного языка – невысока.
- Но! Как демонстрация степенного закона (подавляющее число слов редкие) – их роль очень важна.



Основы обработки текста

Терминология



Токен – экземпляр последовательности символов в документе, объединенных в семантическую единицу для обработки.

Термин – «нормализованный» токен (регистр, морфология, исправленные ошибки и т.п.)



- Необходимо «нормализовывать» термины как в индексируемом тексте, так и в запросе.
- Например: желательно считать одинаковыми термины U.S.A. и USA
- Обычно термины объединяются в классы эквивалентности.
- Можно поступать наоборот, расширять:
 - window → window, windows
 - windows → Windows, windows
 - Windows (нет расширения)
- Такой подход гибкий, но более ресурсоёмкий.



Мы неявно предполагаем:

- Мы знаем, то такое документ.
- Каждый документ доступен для автоматического разбора.

На самом деле, здесь может быть много проблем.

Лингвистика при обработке документов



- Определение формата документа (pdf, word, html и т.д.)
- Определение кодировки документа
- Определение языка документа
- Токенизация и сегментация
- Нормализация и лемматизация;
- Выделение объектов и зон
- Вычисление текстовых факторов

Нормализация



Нормализация зависит от языка документа.

- PETER WILL NICHT MIT. → MIT = mit
- He got his PhD from MIT. → MIT ≠ mit

Ударения и диакритика



- résumé vs. resume
- Умуляуты: Universität vs. Universitaet (заменяем на специальную последовательность «ae» или даже «æ»)
- Самый важный вопрос: как пользователи предпочитают писать запросы с этими словами?

Классы эквивалентности



- Soundex
 - фонетическая эквивалентность, Muller = Mueller
- Тезаурус
 - семантическая эквивалентность, car = automobile

Понижение регистра



- Понизить регистр всех букв.
- Возможны исключения, например, для
- капитализированных слов внутри предложения.
 - MIT и mit
 - Fed и fed
 - КОТ и кот (Калининградская областная таможня)
- NB: немецкий → существительные с большой буквы
- Часто лучше понижать всё, потому что пользователи не заботятся о капитализации в запросах.

Проблемы токенизации: одно слово или два?



- Hewlett-Packard
- State-of-the-art
- co-education
- the hold-him-back-and-drag-him-away maneuver
- data base
- San Francisco
- Los Angeles-based company
- cheap San Francisco-Los Angeles fares
- York University vs. New York University



- 3/20/91
- 20/3/91
- Mar 20, 1991
- B-52
- 100.2.86.144
- (800) 234-2333
- 800.234.2333

Обработка запроса



- Запросы задают не по-русски
- Распознавание языка
- Исправление опечаток
- Токенизация
- Нормализация и лемматизация
- Корелеренция (расширение запроса)
- Переформулировки запросов
- Сегментация запроса
- Извлечение объектов



李克强说，当前国际和地区形势发生复杂深刻变化，中越都处于发展的关键阶段，双方要从战略高度和长远角度出发，在发展中越关系十六字方针和“四好”精神指引下，坚定不移推进中越友好。中方愿同越方保持高层战略沟通，加强治国理政经验交流，坚持经济优先、民生优先，深化务实合作，推动中越全面战略合作伙伴关系迈上新台阶。

(c) news.xinhuanet.com

Китайский: нет пробелов



Или даже так



(c) Baidu.com



文字

Эти два иероглифа могут трактоваться как одно слово «письменность»
или как последовательность двух слов «культура» и «слово»

Другие случаи отсутствия пробелов



- Компаунды в датском, немецком, шведском, финском.
 - Computerlinguistik → Computer + Linguistik
 - Lebensversicherungsgesellschaftsangestellter → leben + versicherung + gesellschaft + angestellter
 - Kallistuksenvaimennusjärjestelmä - система, предотвращающая крен (в погрузчиках).
- Льезоны в романских языках
 - em os → nos
 - por a → pela
- Эскимосы: tusaatsiarunnanngittualuujunga (Я не очень хорошо слышу)
- Таких языков довольно много.



4 разных алфавита.

ローマ字	Romaji
------	--------

平仮名	Hiragana
-----	----------

片仮名	Katakana
-----	----------

漢字	Kanji
----	-------

Запрос может быть сформулирован в любом из них.

Named Entity Recognition



Извлечение объектов (группа слов/токенов в запросе, которые обозначают одно понятие)

- ФИО
- Телефоны
- Адреса
- Даты
- Названия песен, фильмов, книг и т.д.



- ASCII (ISO 646) – 7-битовый стандарт
- ISO 8859
 - 8859-1, или ISO Latin-1
 - ISO 8859-5
- Русские кодировки
 - cp1251 aka Windows
 - 866 aka DOS
 - KOI-8
- Unicode
- UTF-8
- UTF-16

Определение языка



- Подходы
 - Графематический
 - N-граммный
 - Лексический



- Система письменности
 - Кириллица
 - Латиница
 - ...
- Алфавит
 - Русский А ... Я
 - Украинский - не используются Ё, Ъ, Ы, Э, но есть Ѓ, Є, І и Ї
 - Казахский....

Russian	Ukrainian	English	French
^п 1.91 ^по 0.84	^п 1.97 ^на 0.85	^t 3.17 ^th 2.00	es 2.31 es\$ 1.77
^с 1.71 ^пр 0.68	^в 1.75 на\$ 0.73	th 2.48 the 1.62	le 1.97 ^de 0.98
^в 1.68 ^на 0.66	^н 1.68 ^по 0.72	^a 2.41 he\$ 1.44	^d 1.84 le\$ 0.82
^н 1.55 ^и\$ 0.61	на 1.45 ^пр 0.63	he 2.24 ed\$ 0.78	^l 1.74 de\$ 0.76
ст 1.43 ^в\$ 0.60	^з 1.40 ^за 0.59	in 1.94 nd\$ 0.73	on 1.70 ^le 0.72
то 1.29 ^не 0.56	^с 1.25 ^не 0.56	er 1.60 ing 0.73	re 1.48 re\$ 0.68
но 1.23 ть\$ 0.48	ро 1.13 ого 0.54	an 1.54 ^an 0.72	^c 1.46 nt\$ 0.58

- Ранговый
- Марковский



- ???
 - án került vagy től majd új ami ő kategória ben szerint amikor hogy amerikai két ezt mint alatt magyar itt második már
- ???
 - cel cod său cu cea I după ro va județul această în către sunt pe toate astfel ani prin ca departamentul din timpul într
- ???
 - ayrıca iklimi gibi tarafından olu kültür birlikte ula yol tarihinde veya iyi sonra türk bulunan kar çalı göre oldu



- Hungarian
 - án került vagy től majd új ami ő kategória ben szerint amikor hogy amerikai két ezt mint alatt magyar itt második már
- Romanian
 - cel cod său cu cea l după ro va județul această în către sunt pe toate astfel ani prin ca departamentul din timpul într
- Turkish
 - ayrıca iklimi gibi tarafından olu kültür birlikte ula yol tarihinde veya iyi sonra türk bulunan kar çalı göre oldu



- CLD (Compact Language Detector) – C++, Python
 - <http://code.google.com/p/chromium-compact-language-detector/>
- LanguageDetection – Java
 - <http://code.google.com/p/language-detection/>
- Видеолекция (Яндекс, RuSSIR 2012)
 - http://videlectures.net/russir2012_grigoriev_language/

Кореференция: синонимы



Различные способы названия одного и того же объекта

- Синонимы: [“ШАВЕРМА”, “ШАУРМА”]
- Аббревиатуры: [“БМП”, “БОЕВАЯ МАШИНА ПЕХОТЫ”]
- Транслитерация: [“PLAZMA”, “ПЛАЗМА”]
- Грамматические замены: [“ПОЗДРАВЛЕНИЕ”, “ПОЗДРАВИТЬ”]
- Переводы: [“ВОЗДУШНАЯ ТЮРЬМА”, “CON AIR”]
- Джойны: [“АУДИО КОДЕКИ”, “АУДИОКОДЕКИ”]



- Словари синонимов
- Энциклопедические сайты
 - Википедия
 - Тематические сайты (kinopoisk)
- Скобочные написания в документах
- Логи запросов с кликами
- Переформулировки запросов
- Грамматические преобразования
- Языковые модели и дистрибутивная семантика



Дистрибутивная гипотеза

- Значение лингвистической единицы складывается только из ее употребления, использования.
- В мозге хранится сумма всех тех контекстов, в рамках которых мы слышали или видели то или иное слово.
- Это и есть его смысл. Без знания типичных соседей никакой семантики нет.

Вывод:

- Слова с похожими типичными контекстами имеют схожее значение

Дистрибутивная семантика



Счетные модели

- Совместная встречаемость
- Косинусная близость

Predictive models

- word2vec

Усечение окончаний (стемминг)



- Отсекаем самое длинное возможное окончание от слова, надеемся, что это не очень ухудшит результат по сравнению с лемматизацией.
- Для каждого языка свои таблицы окончаний.
- Для некоторых языков другие аналогичные методы.
- Результат довольно смешной:
 - сочи и сочиться приводятся к одной форме.
 - По старому анекдоту про Жуковского - у глагола «ховать» есть форма повелительного наклонения?

Усечение окончаний (стемминг)



Sample text: Such an analysis can reveal features that are not easily visible from the variations in the individual genes and can lead to a picture of expression that is more biologically transparent and accessible to interpretation

Lovins stemmer: such an analysis can reveal features that are not easily visible from the variations in the individual genes and can lead to a picture of expression that is more biologically transparent and accessible to interpretation

Porter stemmer: such an analysis can reveal features that are not easily visible from the variations in the individual genes and can lead to a picture of expression that is more biologically transparent and accessible to interpretation

Paice stemmer: such an analysis can reveal features that are not easily visible from the variations in the individual genes and can lead to a picture of expression that is more biologically transparent and accessible to interpretation

Лучше ли становится от усечения окончаний?



- Усечение окончаний улучшает одни запросы и ухудшает другие.
 - Где хорошо: [tartan sweaters], [sightseeing tour san francisco]
- (классы эквивалентности: {sweater,sweaters}, {tour,tours})
- Алгоритм Портера определяет следующий класс эквивалентности
 - operate operating operates operation operative operatives operational.
- Тогда в этих запросах станет хуже:
 - [operational AND research]
 - [operating AND system]
 - [operative AND dentistry]



- Привести все разные формы к одной начальной.
 - Пример: am, are, is → be
 - Пример: car, cars, car's, cars' → car
 - Пример: the boy's cars are different colors → the boy car be different color
- Лемматизация заключается в поиске правильной основной формы для леммы в словаре.

Лемматизация



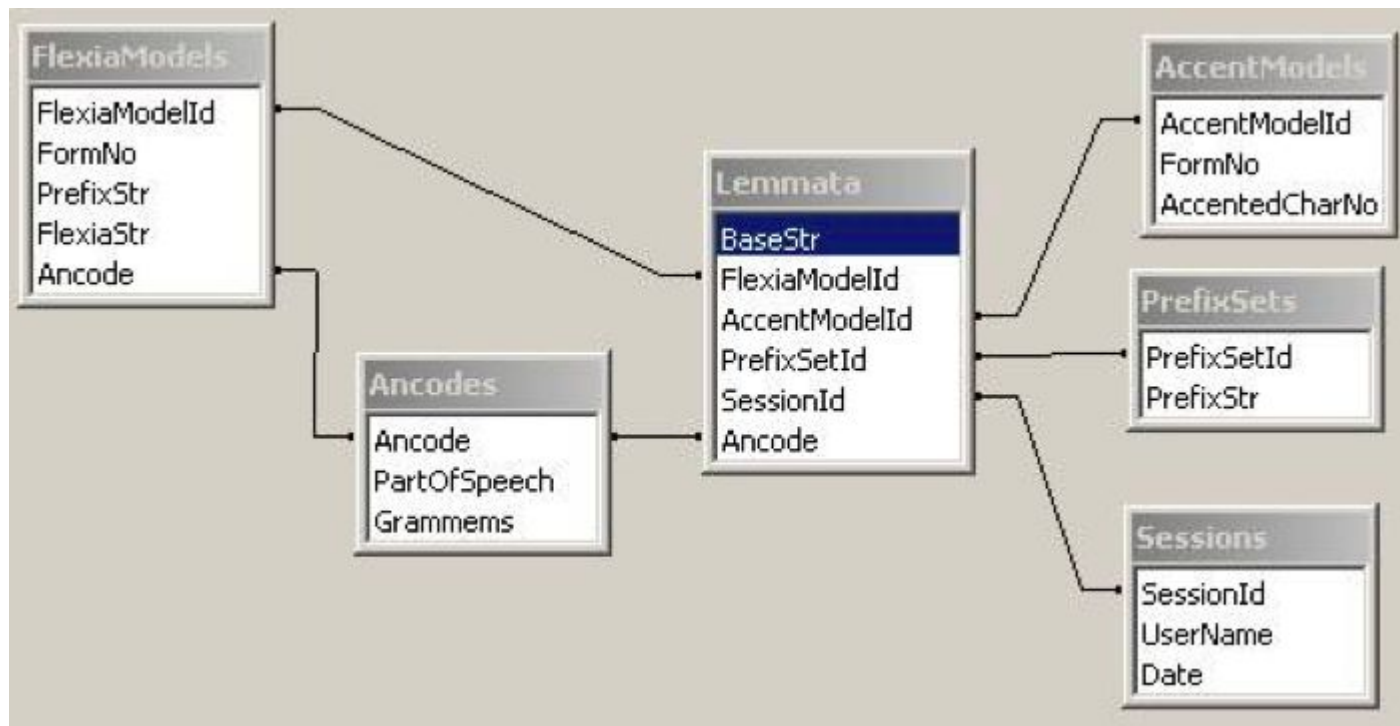
- Слово = машинная основа + парадигма
- Парадигма



- Слово = машинная основа + парадигма
- Парадигма
 - Парадигм а
 - Парадигм ы
 - Парадигм е
 - Парадигм у
 - Парадигм ой
 - Парадигм е



- Слово = машинная основа + парадигма
- Парадигма
 - Парадигм а
 - Парадигм ы
 - Парадигм е
 - Парадигм у
 - Парадигм ой
 - Парадигм е



- Что делать со словами, которых нет в нашем словаре?
- Ищем похожие!

Input Your text:

микроблог

☐ English ☒ Russian ☐ German

☐ With paradigms

Submit Request

Found	Dict ID	Lemma	Grammems	
-	но,	МИКРОБЛОГ	С мр,вн,им,ед,	АНАЛОГ
-		МИКРОБЛГИЙ	КР_ПРИЛ но,од,мр,ед,	НЕДОЛГИЙ

Откуда взять морфологию



- Для английского:
 - Стеммер Портера (Porter)
 - Стеммер Ловинса (Lovins)
- Для русского:
 - aot.ru
 - keva.ru (СтемКа)
 - MyStem (<http://company.yandex.ru/technologies/mystem/>)
- Усекатель окончаний можно сделать самостоятельно.



- Стоп-слова очень часто встречающиеся слова, так что их появление в документе будет иметь мало ценности для выбора этого документа.
- В английском: a, an, and, are, as, at, be, by, for, from, has, he, in, is, it, its, of, on, that, the, to, was, were, will, with
- В русском: и, или, в, и, у, . . .
- Кроме того: 2010, 2011, корзина, . . .
- Ранее стоп-слова практически всегда удалялись.
- Но стоп-слова нужны для цитатного поиска: «King of Denmark», «Бахча У»
- Поисковые системы по вебу индексируют стоп-слова.

Где же проблемы?



- Языки разные
 - Изолирующие/Аналитические
 - Синтетические
 - Флективные
 - Агглютинативные
 - Полисинтетические

Изолирующие/Аналитические



- Изолирующие
 - Низкое отношение «морфема/слово»
- Аналитические
 - Грамматика – отдельными словами
- Китайский
- Английский



- Индо-европейские
 - Русский
 - Испанский
 -

- ФИНСКИЙ

номинатив	talo	house
генитив	talon	of (a) house
эссив	talona	as a house
партитив	taloa	house (as an object)
транслатив	taloksi	to a house
инессив	talossa	in (a) house
элатив	talosta	from (a) house
иллатив	taloon	into (a) house
адессив	talolla	at (a) house
аблатив	talolta	from (a) house
аллатив	talolle	to (a) house
абессив	talotta	without (a) house
комитатив	taloineni	with (my) house(s)



- Тюркские языки

Turkish	English
<i>ev</i>	(the) house
<i>evler</i>	(the) houses
<i>evin</i>	your (sing.) house
<i>eviniz</i>	your (pl./formal) house
<i>evim</i>	my house
<i>evimde</i>	at my house
<i>evlerinizin</i>	of your houses
<i>evlerinizden</i>	from your houses



Чукотско-камчатские, эскимосско-алеутские и т.п.

Тымэйҕылевтпыгтыркын

(t-ə-mejŋ-ə-levt-pəyt-ə-rkən)

У меня сильно болит голова.



Разные по смыслу слова имеют одинаковое написание

Примеры:

белки бегали по лесу и ели орехи

(Лемма: белка, сущ. жен. род)

белки различаются по степени растворимости в воде

(Лемма: белок, сущ. муж. род)

- Словоформа - конкретная морфологическая разновидность слова

белка, белку, белкой, белке

Неоднозначность



- Английский
 - Leg
 - Chair
- Русский
 - Лук
 - Очки
 - Лист

Снятие омонимии



- Rule-based
- Statistical

Rule-based



- X - verb or noun?
 - Preposition + X → X – noun
 - Pronoun + X → X – verb
 - You can do it by request
 - I request a book



//~ TN 26.1.a

//~ TC Если K - омоним с прилагательным или наречием

//~ TA И справа - enough

//~ TA И если омоним - переходный глагол, и справа от enough не
существительное

else if ((IsAdj(k) || IsAdverb(k))

 && CheckQuantitativeParticular(k + 1, QP_ENOUGH)

 && !CheckPrepParticular(k + 2, PP_OF)

 && !(IsTransitiveVerb(k) && IsNoun(k + 2)))

Статистическое снятие омонимии



- Размеченный корпус
- Собираем статистику
- Используем машинное обучение

Для интересующихся:

http://download.yandex.ru/company/Zelenkov_Segalovich.pdf

Рекомендуемая литература

Введение в информационный поиск
| Маннинг Кристофер Д., Шютце
Хайнрих



Для саморазвития (опционально)
Чтобы не набирать двумя
пальчиками

Спасибо за
внимание!

Антон Кухтичев



a.kukhtichev@mail.ru



[@toshunster](https://www.instagram.com/toshunster)