МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ

Урок №5

# Словари и нечёткий поиск

(основано на слайдах Андрея Калинина, Hinrich Schütze, Christina Lioma)

15 октября 2025 года

Антон Кухтичев

# Содержание занятия

1. Словарь
2. Запросы с мета-символами
3. Проверка правописания
4. Soundex
5. Metaphone
6. Исправление запросов

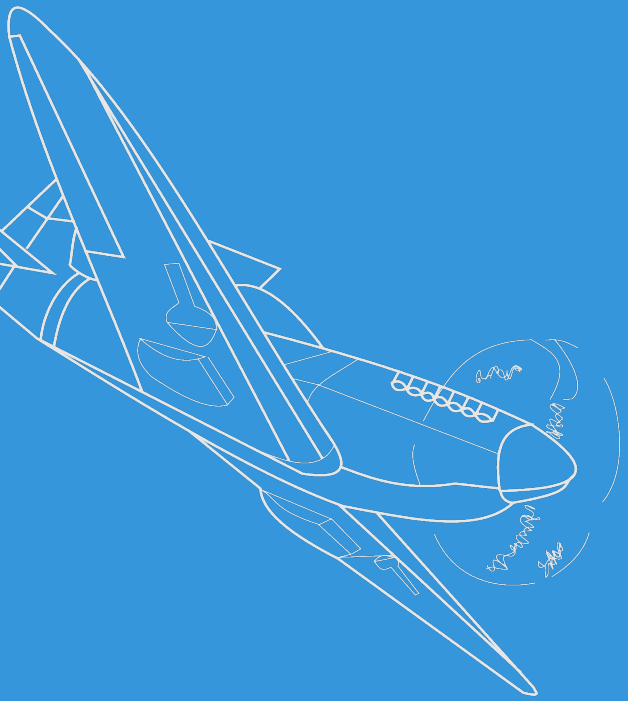

# Словарь

# Обратный индекс

# Словарь как массив

- Для каждого термина нужно сохранить:
  - количество документов (частотность)
  - указатель на координаты
  - …
- На время допустим, что можно представить эту информацию в виде структуры фиксированной длины.
- Тогда можно использовать массив для хранения словаря.

# Словарь как массив

| Термин | Частотность | Координатный блок |
|---|---|---|
| a | 656256 | → |
| aachen | 65 | → |
| … | … | … |
| zulu | 221 | → |
| **объём:** 20 байт | 4 байта | 4 байта |

Как искать термин запроса $q_i$ в этом массиве? То есть: какую структуру данных можно использовать, чтобы найти строку, в котрой находится $q_i$?

# Структуры данных поиска терминов


- Два основных класса: хеши и деревья.
- Некоторые ИСП используют хеши, некоторые — деревья.
- Основные вопросы выбора:
  - Количество терминов фиксировано, или растёт?
  - Какие относительные частоты доступа к разным ключам?
  - Сколько разных ключей имеется?

# Хеши

- Каждый термин хешируется в целое число.
- Боремся с коллизиями.
- Во время запроса: хешируем термин запроса, разрешаем коллизии, находим нужную строку в массиве.
- Плюсы:
  - Поиск в хеш-таблице быстрее, чем поиск в дереве.
  - Время поиска — константа.

# Хеши

- Минусы
  - Нельзя найти небольшие различия (resume и résumé)
  - Нельзя искать по префиксу (все термины, начинающиеся с
  - automat)
  - Для растущего словаря придётся время от времени всё рехешировать.
- Теоретически, можно сделать «морфологическую» хеш-функцию.

# Деревья


- Деревья позволяют искать термины с общим префиксом.
- Простейшее дерево — бинарное.
- Поиск медленее хешей, *O(log M)*, где M — размер словаря.
- *O(log M)* соблюдается для сбалансированных деревьев.
- Так же можно использовать B-деревья.

# Бинарное дерево

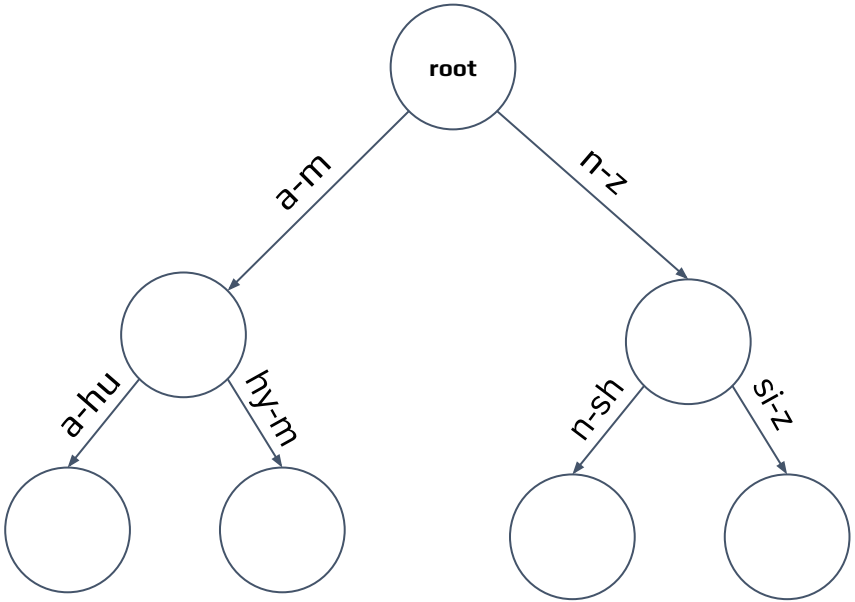

# B-дерево

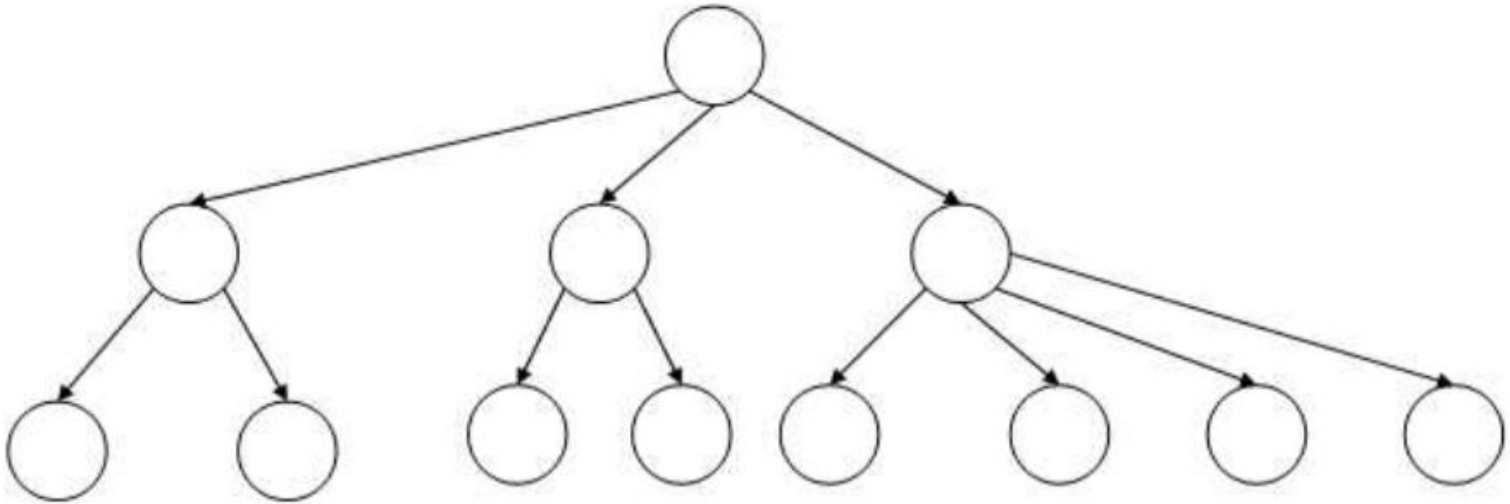

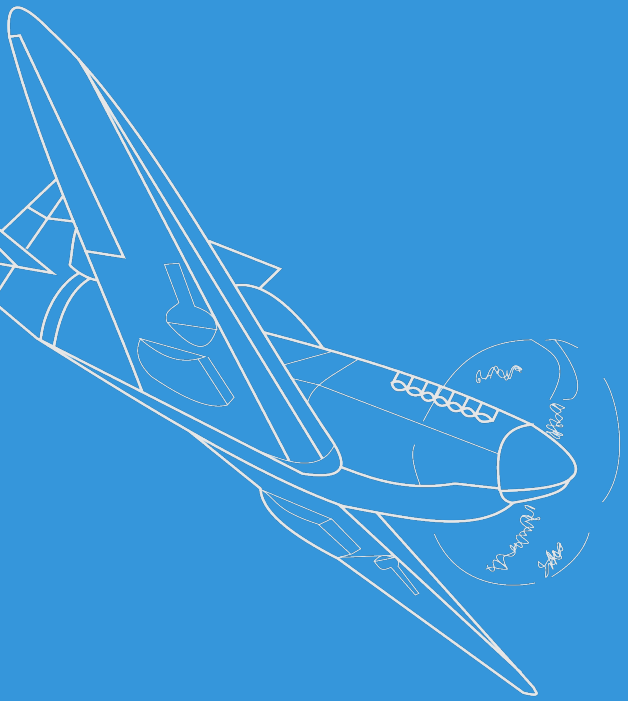

# Запросы с мета-символами

# Запросы с мета-символами

- mon*: найти все документы, содержащие термин, начинающийся с mon
- Просто для B-дерева: найти все термины t, находящиеся в диапазоне mon ≤ t < moo
- *mon: найти все термины, заканчивающиеся на mon
  - Создаём дополнительное дерево, для терминов, записанных задом наперёд.
  - Теперь по этому дереву получаем термины t в диапазоне nom ≤ t < non
- Результат: множество терминов, подходящих под маску.
- Теперь нужно найти документы, содержащие любой из этих терминов.

# Как обработать * внутри термина


- Например: `m*nchen`
- Можно поискать `m*` и `*nchen` в B-деревьях и пересечь два полученных множества.
- Довольно расточительно.
- Альтернатива: индекс перестановок
- Основная идея: «переворачивать» каждый запрос с маской таким образом, чтобы * оказалась в конце.
- Хранить каждый переворот каждого термина в словаре, в том же B-дереве.

# Индекс перестановок


- Для термина hello: добавим *hello$, ello$h, llo$he, lo$hel, и o$hell* в B-дерево, где $ — специальный символ.

# Отображение перестановок в термины

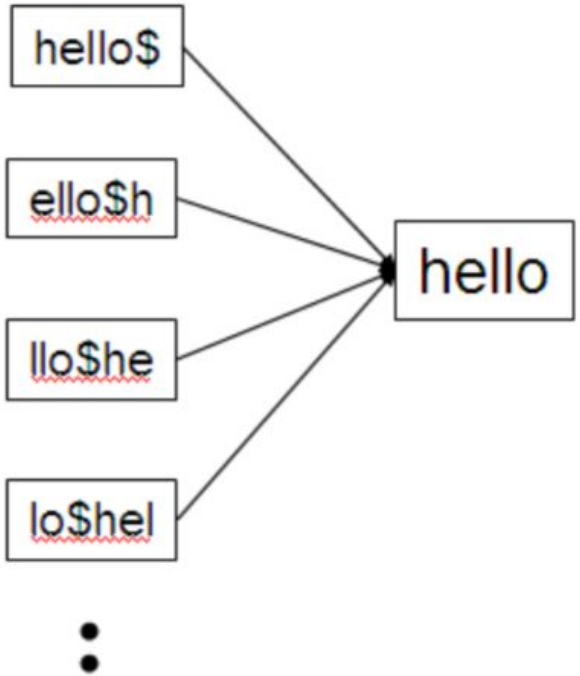

# Индекс перестановок


- Итак, для `hello` храним: `hello$`, `ello$h`, `llo$he`, `lo$hel` и `o$hell`
- Тогда запросы
  - X, ищем X$
  - X*, ищем X*$
  - *X, ищем X$*
  - *X*, ищем X*
  - X*Y, ищем Y$X*
  - Например: для `hel*o` ищем `o$hel*`
  - Как обработать запрос X*Y*Z?

# Поиск в индексе перестановок

- Прокрутить запрос так, чтобы * была справа.
- Искать как обычно.
- Однако: такой индекс как минимум учетверяет размер словаря (для английского языка, для русского — увеличит в 7-8 раз).

# Индексы *k*-грамм


- Занимает меньше места, чем индекс перестановок.
- Индексируем все символьные *k*-граммы (последовательности из k символов) термина.
- 2-граммы часто называют биграммами.
- Например: из `April is the cruelest month` получим следующие биграммы: `$a ap pr ri il l$ $i is s$ $t th he e$ $c cr ru ue el le es st t$ $m mo on nt h$`
- `$` — специальный символ, обозначающий границу слова.
- Добавляем в новый индекс не термины, а биграммы.

# 3-граммный обратный индекс

# k-граммные индексы


- Теперь у нас два разных вида обратных индексов.
- Есть индекс терминов-документов.
- И есть индекс *k*-грамм, чтобы находить термины по запросам, состоящие из *k*-грамм.

# Выполнение запроса с метасимволами для биграмм

- Запрос `mon*` можно обработать так:

  `$m and mo and on`

- Так получим все термины с префиксом mon...
- ... но и много «ложных срабатываний», таких как `moon`.
- Их нужно отфильтровать, напрямую сравнивая термины с запросом.
- Оставшиеся термины нужно искать в индексе терминов-документов.
- *k*-граммный индекс и индекс перестановок
  - *k*-граммный индекс занимает меньше места.
  - Индекс перестановок не требует пост-фильтрации.

# Упражнение

Почему у больших веб-поисков нет поддержки запросов с масками?

# Упражнение

Почему у больших веб-поисков нет поддержки запросов с масками?

- Много слов.
- Увеличивается количество обрабатываемых терминов.
- Люди будут вводить меньше символов в словах.

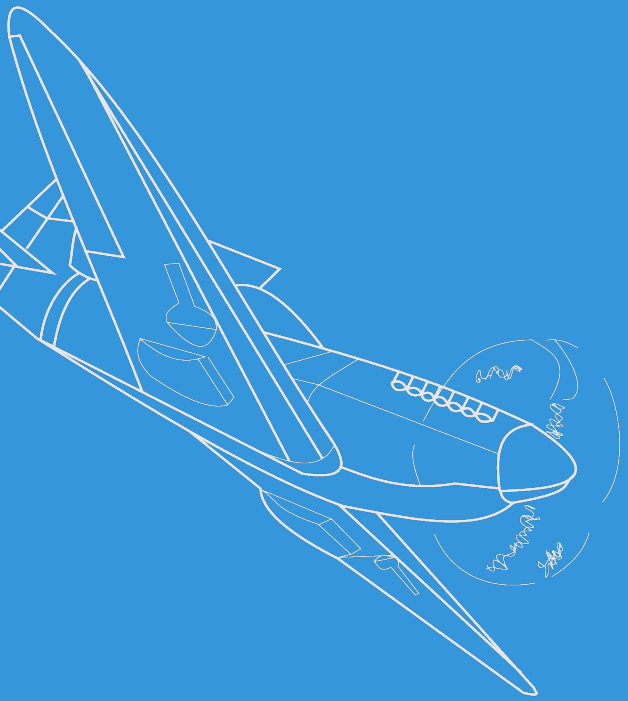

# Проверка правописания

# Проверка правописания

- Два возможных применения:
  - Исправление документов.
  - Исправление запросов.
- Два разных метода:
  - Исправление отдельных слов
    - Проверяет каждое слово.
    - Не сможет исправить опечатки в словарных терминах, например [an asteroid that fell form the sky]
  - Контекстно-зависимое исправление
    - Обращает внимание на контекст, окружающие слова.
    - Может заменить ошибку в предыдущем примере (form/from)

# Исправление документов

- Интерактивная коррекция документов не нужна.
- Используется в основном для распознанных документов (системы OCR).
- Обычно документы никак не изменяются.

# Исправление запросов


- Самое простое: исправление отдельных слов
- Допущение 1: имеется список «правильных слов».
- Допущение 2: есть способ вычисления расстояния между словом с опечаткой и правильным словом.
- Тогда простейший алгоритм возвращает «правильное» слово с наименьшим расстоянием к слову с опечаткой.
- Например: `informaton` → `information`
- В качестве списка правильных слов можно использовать словарь ИПС.
- Почему это плохо?

# Альтернативные источники «правильных» слов

- Стандартные словари (Зализняк)
- Технические словари (для специализированных ИПС)
- Отфильтрованные словари корпуса ИПС

# Расстояния между словами

- Две альтернативы:
  - Расстояние Левенштейна
    - Взвешенное расстояние Левенштейна
  - Пересечение k-грамм

# Расстояние Левенштейна

- Расстояние между строками $s_1$ и $s_2$ — количество элементарных операций редактирования, нужных для преобразования $s_1$ в $s_2$.
- Растояние Левенштейна: операции вставки, удаления и замены.
  - dog-do: 1
  - cat-cart: 1
  - cat-cut: 1
  - cat-act: 2
- Расстояние Левенштейна-Дамерау: добавлена операция перестановки двух рядом стоящих символов.
  - cat-act: 1

# Вычисление расстояния Левенштейна

| | | f | a | s | t |
|---|---|---|---|---|---|
| | 0 | 1 | 2 | 3 | 4 |
| c | 1 | 1 | 2 | 3 | 4 |
| a | 2 | 2 | 1 | 2 | 3 |
| t | 3 | 3 | 2 | 2 | 2 |
| s | 4 | 4 | 3 | 2 | 3 |

# Расстояние Левенштейна: вычисление

**Algorithm** Edit distance

**Input**: $\alpha = \alpha_1 \dots \alpha_n$ and $\beta = \beta_1 \dots \beta_m$

```
1:  for i ← 0 to n  do
2:      D_{i,0} ← i;
3:  end for
4:  for j ← 0 to m  do
5:      D_{0,j} ← j;
6:  end for
7:  for i ← 1 to n  do
8:      for j ← 1 to m do
9:          t ← (α_i = β_j)? 0 : 1;
10:         D_{i,j} ← min{D_{i-1,j-1} + t, D_{i,j-1} + 1, D_{i-1,j} + 1};
11:     end for
12:  end for
13. return D_{n,m}
```

# Взвешенное расстояние


- Аналогично предыдущему, но веса операций зависят от символов.
- Нужно для учёта клавиатурных опечаток, например m более вероятно ошибочно напечатать как n, чем как q.
- Поэтому, замена m на n — меньшее расстояние, чем замена на q.
- Теперь нужна матрица весов.
- Так же нужно добавить в алгоритм учёт этих весов.

# Исправление опечаток с учётом весов

- Для данного запроса перебрать все строки на заданном расстоянии.
- Пересечь это множество со списком «правильных» слов.
- Предложить термины из пересечения пользователю.
- Или автоматически исправить запрос.
- Что лучше?

# k-граммный индекс для исправления опечаток


- Перебрать все k-граммы из термина запроса
- Например: биграммный индекс, слово с опечаткой `bordroom`
- Биграммы: `bo, or, rd, dr, ro, oo, om`
- Используем индекс k-грамм для получения «правильных» слов
- Устанавливаем предел по количеству совпавших k-грамм
- Например, нужны только такие термины, которые отличаются не больше чем по трём k-граммам.

# Исправление опечатки для bordroom

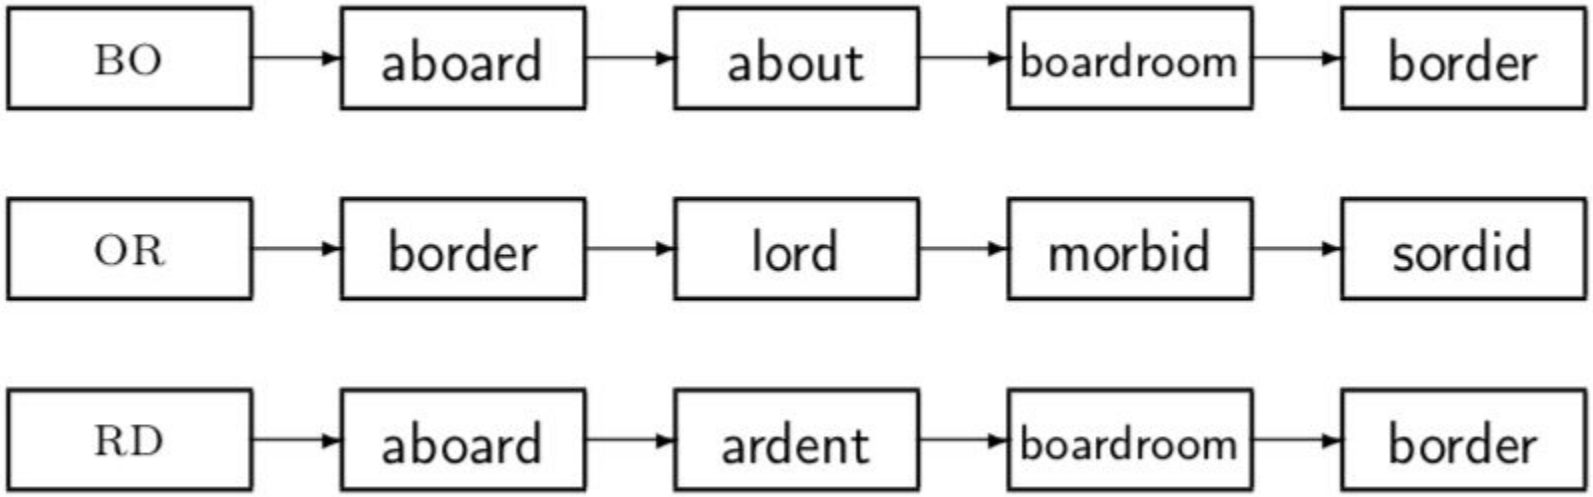

# Пример с триграммами

- Проблема: фиксированное количество отличающихся k-грамм по разному работает для слов разной длины.
- Например, правильное слово `november`
  - Триграммы: `nov`, `ove`, `vem`, `emb`, `mbe`, `ber`
- И запрос `december`
  - Триграммы: `dec`, `ece`, `cem`, `emb`, `mbe`, `ber`
- Таким образом, 3 триграммы пересекаются (из 6 у каждого термина)
- Нужна нормализованная метрика.

# Коэффициент Жаккара

- Метрика пересечения двух множеств.
- Два множества, A и B
- Коэффициент Жаккара: $\frac{|A \cap B|}{|A \cup B|}$
- A и B не обязаны иметь одинаковый размер.
- Результат — число между 0 и 1.
- december/november — какой коэффициент Жаккара?
- В проверке правописания можно использовать в качестве лимита, исправлять только для значений коэффициента > 0.8.

# Контекстно-зависимая проверка (1)


- Пример: `an asteroid that fell form the sky`
- Как можно исправить слово form?
- Одна из идей: статистика вхождений.
  - Получить «правильные» термины, близкие к каждому термину.
  - Для запроса `flew form munich`: flea для flew, from для form, munch для munich

# Контекстно-зависимая проверка (2)


- Поискать все возможные варианты с одним исправленным словом:
  - Сначала “`flea form munich`”
  - Затем “`flew from munich`”
  - Потом “`flew form munch`”
- Правильный запрос “`flew from munich`” вернёт больше всего результатов.

- Допустим, у нас есть 7 вариантов для flew, 20 для form и 3 for munich, сколько запросов на проверку получится?

# Контекстно-зависимая проверка (3)

- Алгоритм на предыдущем слайде не очень эффективен.
- Лучшая альтернатива — исследовать запросы, а не документы.

# Общие проблемы исправления опечаток

- Пользовательский интерфейс:
  - Заменять автоматически или предлагать?
  - Возможно, Вы имели в виду подходит только для одного предложения.
  - Что делать с большим количеством вариантов?
  - Компромисс между простым или гибким интерфейсом.
- Затраты:
  - Потенциально очень затратно.
  - Обрабатывать выборочно?
  - Например, только для запросов, вернувших мало результатов.
  - Исправление опечаток для крупных ИПС достаточно быстро работает, чтобы обслуживать каждый запрос.

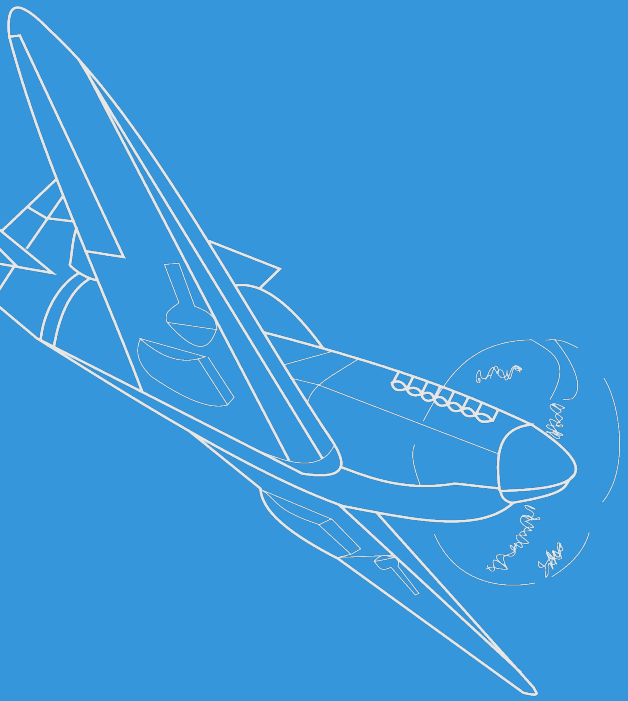

# Soundex

# Soundex


- Soundex — алгоритм нахождения фонетических альтернатив.
- Например: chebyshev / tchebyscheff
- Алгоритм:
  - Преварить каждый токен в 4-х символьную сокращённую форму.
  - То же самое сделать для терминов запроса.
  - Построить и использовать отдельный индекс сокращённых форм.

# Алгортим Soundex

1. Оставим первый символ термина.
2. Следующие символы заменяются на ‘0’ (ноль): A, E, I, O, U, H, W, Y
3. Заменить символы на цифры:
   a. B,F,P,V на 1
   b. C,G,J,K,Q,S,X,Z на 2
   c. D,T на 3
   d. L на 4
   e. M,N на 5
   f. R на 6
4. Повторно удалять по цифре из последовательных повторов.
5. Удалить все нули. Добавить в конец нули так, чтобы в оставшемся коде было бы как минимум 4 знака. Вернуть код из 4-х знаков: буква на первой позиции и первые три цифры.

# Soundex для HERMAN

- Оставим H
- ERMAN → ORMON
- ORMON → 06505
- 06505 → 06505
- 06505 → 655
- Результат: H655
- Для HERMANN будет сгенерирован тот же код.

# Насколько полезен Soundex?

- Для информационного поиска не очень.
- Подходит для задач с высоким уровнем полноты, например,

  Интерпол использует Soundex для своей картотеки.
- Существуют лучшие альтернативы.
- Есть адаптации для русского языка, не очень хорошие.

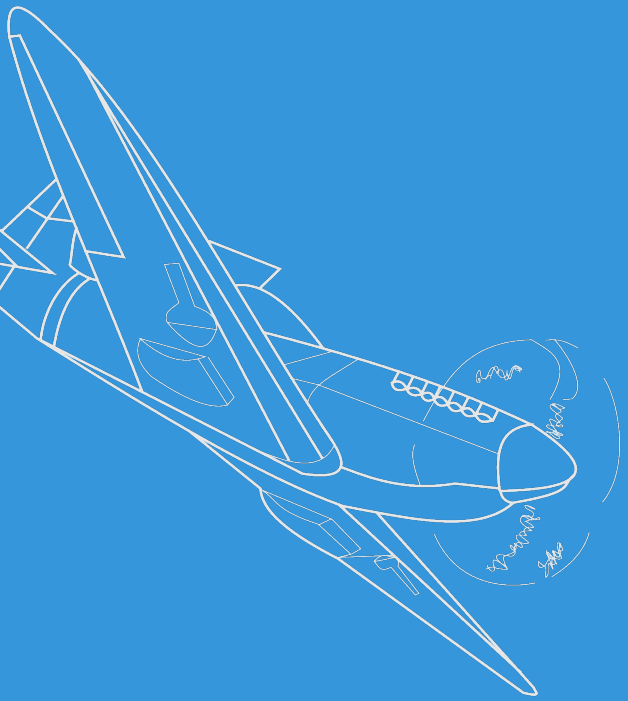

# Metaphone

Улучшенная альтернатива Soundex

# Metaphone


- 

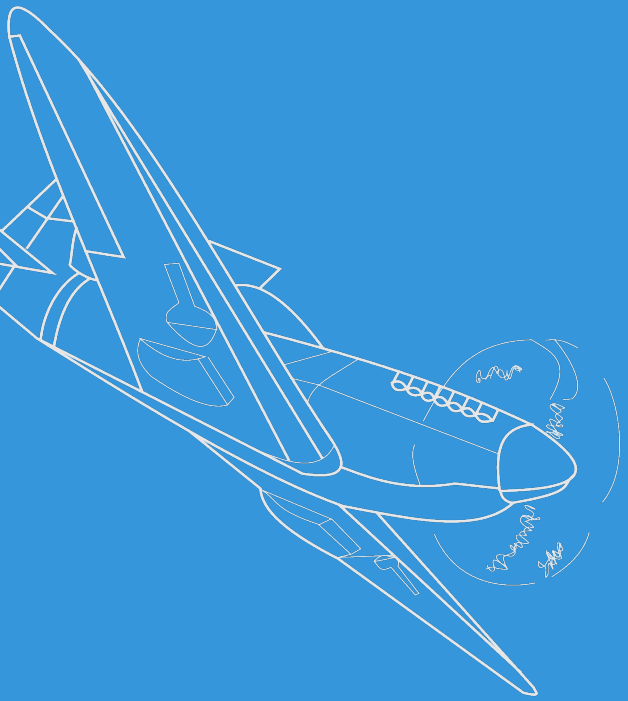

# Исправление запросов

# Бритни Спирс: https://archive.google.com/jobs/britney.html


| | | | | | |
|---|---|---|---|---|---|
| 488941 britney spears | 29 britent spears | 9 brinttany spears | 5 brney spears | 3 britiy spears | 2 brirreny spears |
| 40134 brittany spears | 29 brittnany spears | 9 britanay spears | 5 broitney spears | 3 britmeny spears | 2 brirtany spears |
| 36315 brittney spears | 29 britttany spears | 9 britinany spears | 5 brotny spears | 3 britneeey spears | 2 brirttany spears |
| 24342 britany spears | 29 btiney spears | 9 britn spears | 5 bruteny spears | 3 britnehy spears | 2 brirttney spears |
| 7331 britny spears | 26 birttney spears | 9 britnew spears | 5 btiyney spears | 3 britnely spears | 2 britain spears |
| 6633 briteny spears | 26 breitney spears | 9 britneyn spears | 5 btrittney spears | 3 britnesy spears | 2 britane spears |
| 2696 britteny spears | 26 brinity spears | 9 britrney spears | 5 gritney spears | 3 britnetty spears | 2 britaneny spears |
| 1807 briney spears | 26 britenay spears | 9 brtiny spears | 5 spritney spears | 3 britnex spears | 2 britania spears |
| 1635 brittny spears | 26 britneyt spears | 9 brtittney spears | 4 bittny spears | 3 britneyxxx spears | 2 britann spears |
| 1479 brintey spears | 26 brittan spears | 9 brtny spears | 4 bnritney spears | 3 britnity spears | 2 britanna spears |
| 1479 britanny spears | 26 brittne spears | 9 brytny spears | 4 brandy spears | 3 britntey spears | 2 britannie spears |
| 1338 britiny spears | 26 btittany spears | 9 rbitney spears | 4 brbritney spears | 3 britnyey spears | 2 britannt spears |
| 1211 britnet spears | 24 beitney spears | 8 birtiny spears | 4 breatiny spears | 3 britterny spears | 2 britannu spears |
| 1096 britiney spears | 24 birteny spears | 8 bithney spears | 4 breetney spears | 3 brittneey spears | 2 britanyl spears |
| 991 britaney spears | 24 brightney spears | 8 brattany spears | 4 bretiney spears | 3 brittnney spears | 2 britanyt spears |
| 991 britnay spears | 24 brintiny spears | 8 breitny spears | 4 brfitney spears | 3 brittnyey spears | 2 briteeny spears |
| 811 brithney spears | 24 britanty spears | 8 breteny spears | 4 briattany spears | 3 brityen spears | 2 britenany spears |
| 811 brtiney spears | 24 britenny spears | 8 brightny spears | 4 brieteny spears | 3 briytney spears | 2 britenet spears |
| 664 birtney spears | 24 britini spears | 8 brintay spears | 4 briety spears | 3 brltney spears | 2 briteniy spears |
| 664 brintney spears | 24 britnwy spears | 8 brinttey spears | 4 briitny spears | 3 broteny spears | 2 britenys spears |
| 664 briteney spears | 24 brittni spears | 8 briotney spears | 4 briittany spears | 3 brtaney spears | 2 britianey spears |
| 601 bitney spears | 24 brittnie spears | 8 britanys spears | 4 brinie spears | 3 brtiiany spears | 2 britin spears |
| 601 brinty spears | 21 biritney spears | 8 britley spears | 4 brinteney spears | 3 brtinay spears | 2 britinary spears |
| 544 brittaney spears | 21 birtany spears | 8 britneyb spears | 4 brintne spears | 3 brtinney spears | 2 britmy spears |
| 544 brittnay spears | 21 biteny spears | 8 britnrey spears | 4 britaby spears | 3 brtitany spears | 2 britnaney spears |
| 364 britey spears | 21 bratney spears | 8 britnty spears | 4 britaey spears | 3 brtiteny spears | 2 britnat spears |
| 364 brittiny spears | 21 britani spears | 8 brittner spears | 4 britainey spears | 3 brtnet spears | 2 britnbey spears |
| 329 brtney spears | 21 britanie spears | 8 brottany spears | 4 britinie spears | 3 brytiny spears | 2 britndy spears |
| 269 bretney spears | 21 briteany spears | 7 baritney spears | 4 britinney spears | 3 btney spears | 2 britneh spears |
| 269 britneys spears | 21 brittay spears | 7 birntey spears | 4 britmney spears | 3 drittney spears | 2 britneney spears |
| 244 britne spears | 21 brittinay spears | 7 biteney spears | 4 britnear spears | 3 pretney spears | 2 britney6 spears |
| 244 brytney spears | 21 brtany spears | 7 bitiny spears | 4 britnel spears | 3 rbritney spears | 2 britneye spears |
| 220 breatney spears | 21 brtiany spears | 7 breateny spears | 4 britneuy spears | 2 barittany spears | 2 britneyh spears |
| 220 britiany spears | 19 birney spears | 7 brianty spears | 4 britnewy spears | 2 bbbritney spears | 2 britneym spears |
| 199 britnney spears | 19 birtney spears | 7 brintye spears | 4 britnmey spears | 2 bbitney spears | 2 britneyyy spears |
| 163 britnry spears | 19 britnaey spears | 7 britianny spears | 4 brittaby spears | 2 bbritny spears | 2 britnhey spears |
| 147 breatny spears | 19 britnee spears | 7 britly spears | 4 brittery spears | 2 bbrittany spears | 2 britnjey spears |
| 147 brittiney spears | 19 britony spears | 7 britnej spears | 4 britthey spears | 2 beitany spears | 2 britnne spears |

# Система исправления опечаток в запросах

- Дипломная работа Татьяны Романовой.
- Защищена в 2010-м году на оценку «отлично».

# Ошибки в запросах

- Около 10 % запросов содержат ошибки.

Распределение ошибок по типам:

1. Орфграфические (видио, кораловый)
2. Опечатки (аэропорь, в отрданом)
3. Фамилии и бренды (том соер, нафтезин)
4. Транслитерация (ntrcns вместо тексты)
5. Пробелы (нтвсмотреть, нижний нов город)
6. Контекстные (свиной гриб, вокруг меха)
7. Иностранные слова (lie to mi, clinitec)

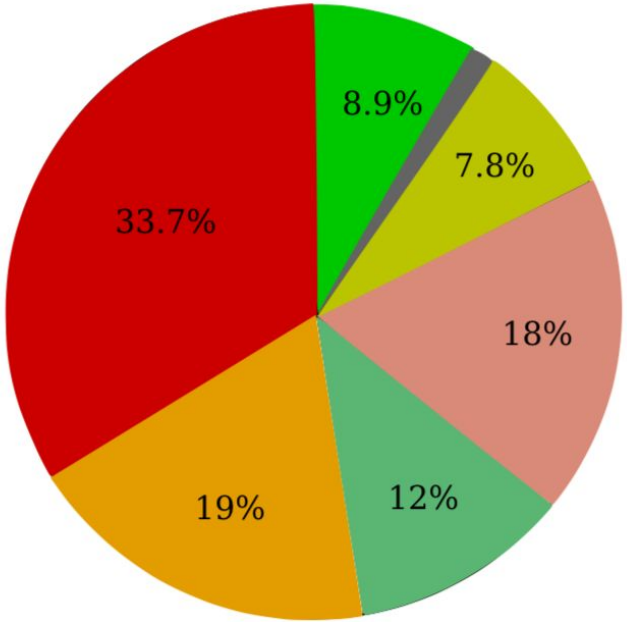

# Источники данных

- Списки введенных запросов (логи):
  1. Большой лог запросов — 11 млн. запросов.
  2. Тематические логи запросов — 10–40 тыс. запросов.
  3. Частотный словарь русского языка — 30 тыс. слов.
- Словари:
  1. Словарь юниграмм — 1 млн. слов.
  2. Словарь биграмм — 7 млн. словосочетаний.

# Общая идея

Имея запрос $q_t$, найдем запрос $q_c$ так, чтобы:

$$P(q_c|q_t) \to \max_{q_c \in \Sigma^*}$$

По формуле Байеса:

$$P(q_c|q_t) = \frac{P(q_t|q_c)P(q_c)}{P(q_t)}$$

Итеративное исправление запроса:

растояие левиштейна → растояние левинштейна → расстояние левенштейна

# Шаги одной итерации

1. Разбить запрос на части;
2. Для каждой части составить список вариантов замен;
3. Оценить вес каждой замены;
4. Составить граф слов;
5. Найти оптимальный путь в графе — алгоритм Витерби.

# Рекомендуемая литература

[Введение в информационный поиск | Маннинг Кристофер Д., Шютце Хайнрих]

Для саморазвития (опционально)

[Чтобы не набирать двумя пальчиками]

# Спасибо за внимание!

**Антон Кухтичев**

a.kukhtichev@mail.ru

@toshunster