МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ

Урок №7

Сжатие координатных блоков

(основано на слайдах Андрея Калинина, Hinrich Schütze, Christina Lioma)

11 ноября 2021 года

Антон Кухтичев

Содержание занятия

1. Введение
2. Сжатие словаря
3. Сжатие координатных блоков

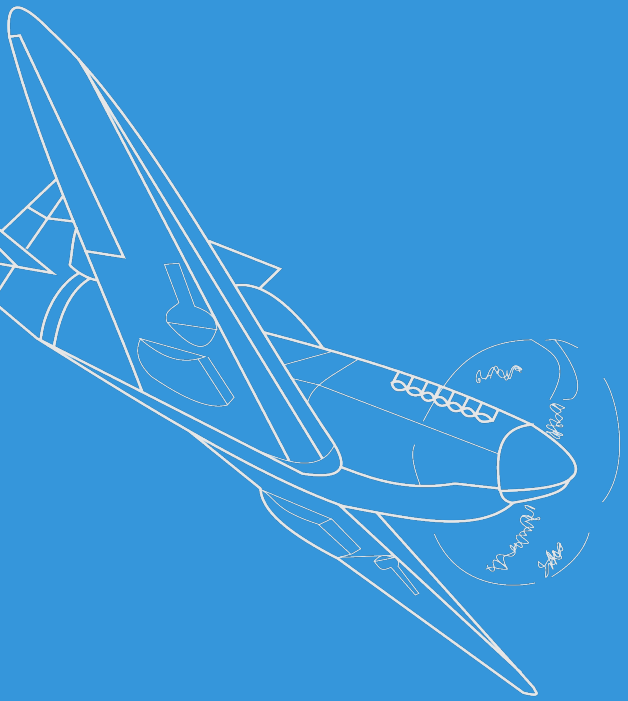

Введение

Зачем сжимать?

- Меньше места
  - Экономим деньги
- Больше помещается в память
  - Увеличивается скорость
- Увеличивается скорость передачи данных между диском и оперативной памятью
  - [прочитать сжатое | распаковать] быстрее, чем [прочитать несжатое]
  - Это выполняется, если алгоритмы распаковки быстрые
    - Поэтому будем рассматривать специальные методы

Зачем сжимать индекс?

- Словарь
  - Добиться, чтобы словарь поместился в память
  - Уменьшить настолько, чтобы освободить место под координатные блоки
- Координатные блоки
  - Уменьшить объём на диске
  - Уменьшить время чтения с диска
  - Крупные поисковики хранят большую часть КБ в памяти
    - Сжатие позволяет хранить больше.
- Рассмотрим несколько специфичных методов сжатия

Корпус новостей Reuters RCV1

N	документы	800,000
L	токенов на документ	200
M	термины	400,000
	байтов на токен (с пробелами и пункт.)	6
	байтов на токен (без проблов/пункт.)	4.5
	байтов на термин	7.5
T	постингов без координат	100,000,000

Связь размера индекса и параметров индексации

Размер …	терминов			постингов			координат		
	словарь			индекс без координат			координатный индекс		
	Размер (KiB)	Δ %	всего %	Размер (KiB)	Δ %	всего %	Размер (KiB)	Δ %	всего%
Всё	484			109,971			197,879		
Без чисел	474	-2	-2	100,680	-8	-8	179,158	-9	-9
Капитализация	392	-17	-19	96,969	-3	-12	179,158	0	-9
30 стоп-слов	391	-0	-19	83,390	-14	-24	121,858	-31	-38
150 стоп-слов	391	-0	-19	67,002	-30	-39	94,517	-47	-52
Без окончаний	322	-17	-33	63,812	-4	-42	94,517	0	-52

Сжатие с потерями и без

- Сжатие без потерь: вся информация остаётся как есть.
  - Обычно используем её в ИП.
- Сжатие с потерями: Что-то считаем возможным убрать
- Понижение капитализации, стоп-слова, морф. нормализация – может рассматриваться как сжатие с потерями.
- Ещё – удаление координат для позиций, которые вряд ли будут вверху на ранжировании.

Размер словаря относительно размера корпуса (1)

- Насколько велик словарь?
  - Т.е., сколько разных слов?
- Можем ли найти верхнюю границу?
  - Нет: $70^{20} = 10^{37}$ разных слов длины 20
- На практике, размер словаря растёт с размером корпуса
  - Особенно для Unicode

Размер словаря относительно размера корпуса (2)

- Закон Хипса: $M = kT^{\beta}$
- M – размер словаря, T – количество токенов
- Обычно: $30 \leq k \leq 100$ и $\beta \approx 0.5$
- На логарифмическом графике (log-log) M от T, этот закон предсказывает линию под углом ½
  - Простейшая связь в log-log
  - Эмпирический закон (основанный на наблюдениях)

Закон Хипса

Для RCV1 пунктирная линия

$\log_{10} M = 0.49 \log_{10} T + 1.64$ МНК-оптимизация закона.

Так, $M = 10^{1.64} T^{0.49}$ отсюда $k = 10^{1.64} \approx 44$ и $\beta = 0.49$.

Хорошее предсказание для Reuters RCV1 !

Для первых 1,000,020 токенов закон предсказывает 38,323 терминов;

На самом деле – 38,365

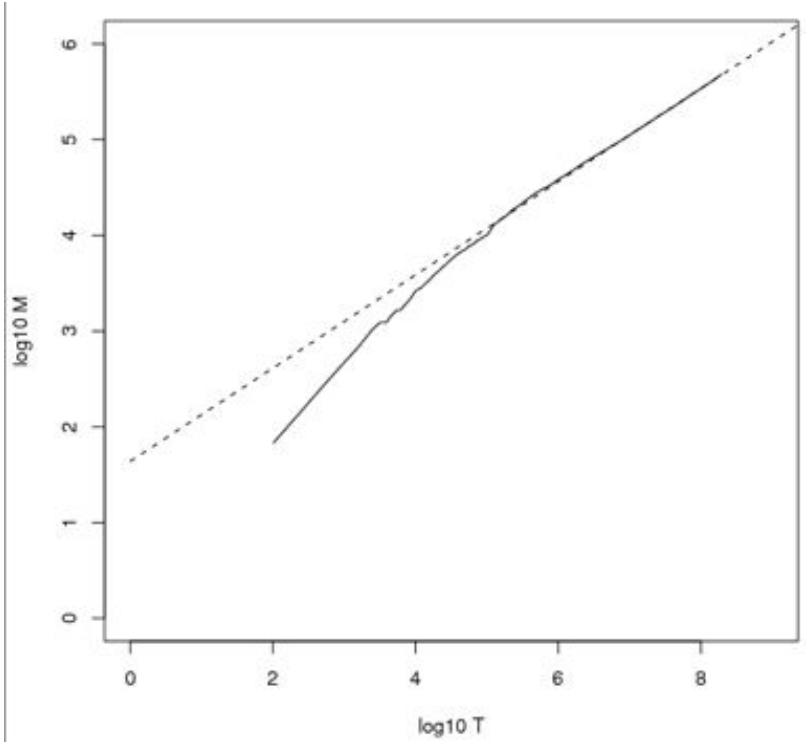

Закон Ципфа

- Нас интересуют относительные частотности терминов.
- В естественном языке немного частых терминов и много редких.
- Закон Ципфа: i-ый самый частый термин имеет частоту $\sim 1/i$.
- $cf_i \propto 1/i = K/I$ где K – нормализующая константа
- cf_i – корпусная частота, сколько раз t_i встретился в корпусе

Следствия из закона Ципфа

- Если самый частый терм (*the*, для английского) встречается cf_1 раз
- Тогда следующий самый частотный термин (*of*) встречается $cf_1/2$ раз
- Третий (and) – $cf_1/3$ …
- Т.е.: $cf_i = K/i$, где K – нормализующий коэффициент, тогда
- $\log cf_i = \log K - \log i$
- Линейная зависимость между $\log cf_i$ и $\log i$

- Ещё один пример степенного закона

Закон Ципфа для Reuters RCV1

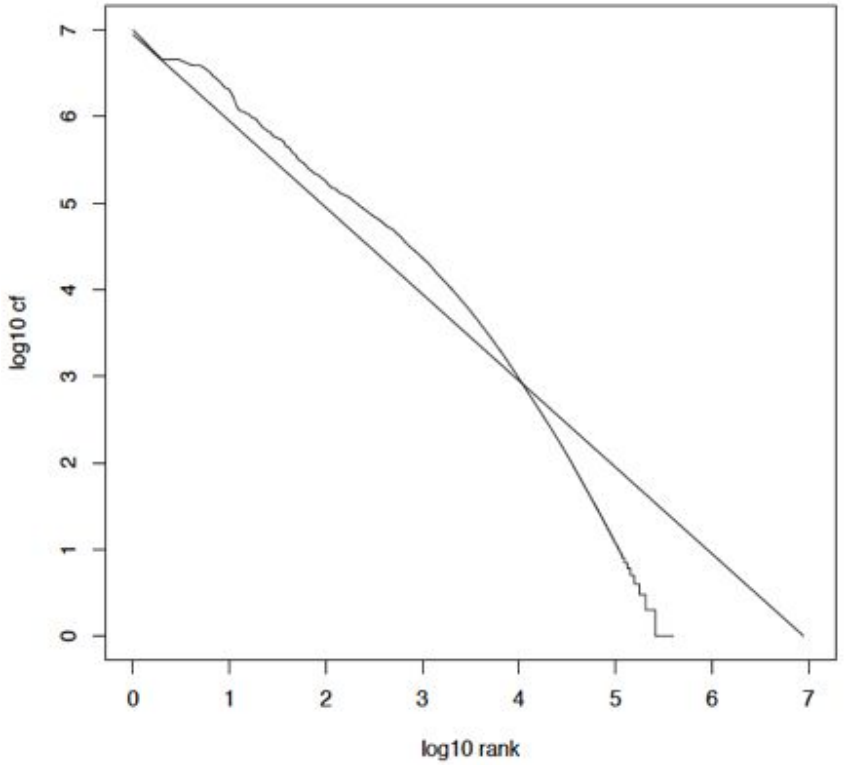

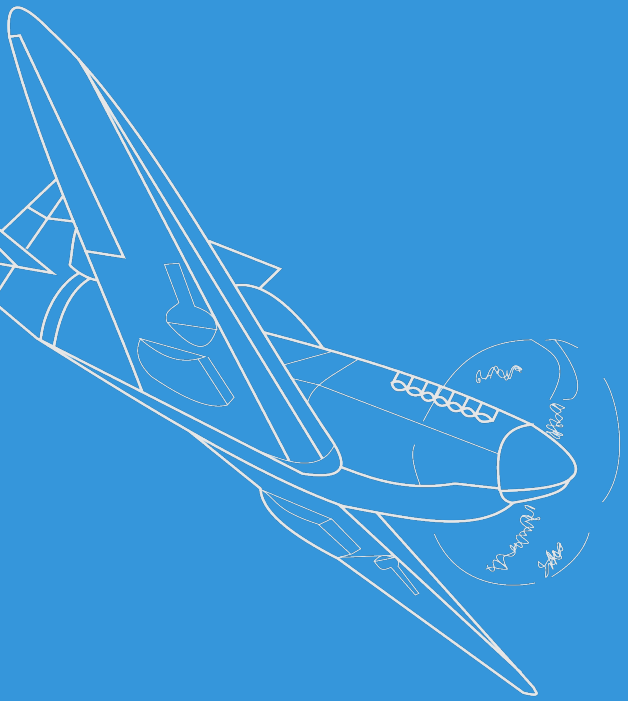

Сжатие словаря

Задача: построить обратный индекс

Зачем сжимать словарь?

- Поиск начинается со словаря.
- Мы хотим хранить его в памяти.
- При этом мы хотим занять как можно меньше памяти (освободить её для других задач)
- Мобильные устройства могут иметь мало памяти.
- Даже если словарь в память не поместился, мы всё равно хотим быстро его загружать при обращениях.
- Итак, сжатие словаря – важная задача.

Хранение словаря – первый подход

- Массив структур фиксированного размера
  - ~400,000 терминов; 28 байтов на термин = 11.2 Mb.

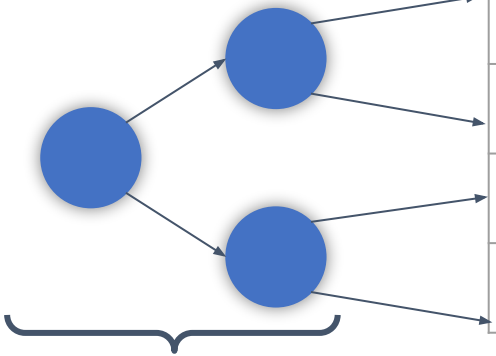

Термин	Частота	Указатель на КБ
a	656,265	
aachen	65	
…	…	
zulu	221	

Дерево поиска | 20 байт | 4 байта | 4 байта

Фиксированная длина терминов

- Большая часть байтов в столбце терминов ни на что не используется – 20 байтов отводится на хранение однобуквенных терминов.
  - И мы всё равно не можем сохранить термины вида *гексакосиойгексеконтагексапараскаведекатриафоб* или *этилоксиэтилпарафенилендиаминсульфат*.
- В письменном английском ~4.5 символа на слово.
- Средняя длина слова в английском словаре: ~8 символов
- Короткие слова преобладают в тексте, но не в словаре.

Сжатие списка терминов: представляем словарь строкой

- Словарь – длинная строка:
- Указатель на следующее слово указывает на конец текущего.
- Надеемся на 60%-ное уменьшение размера словаря.

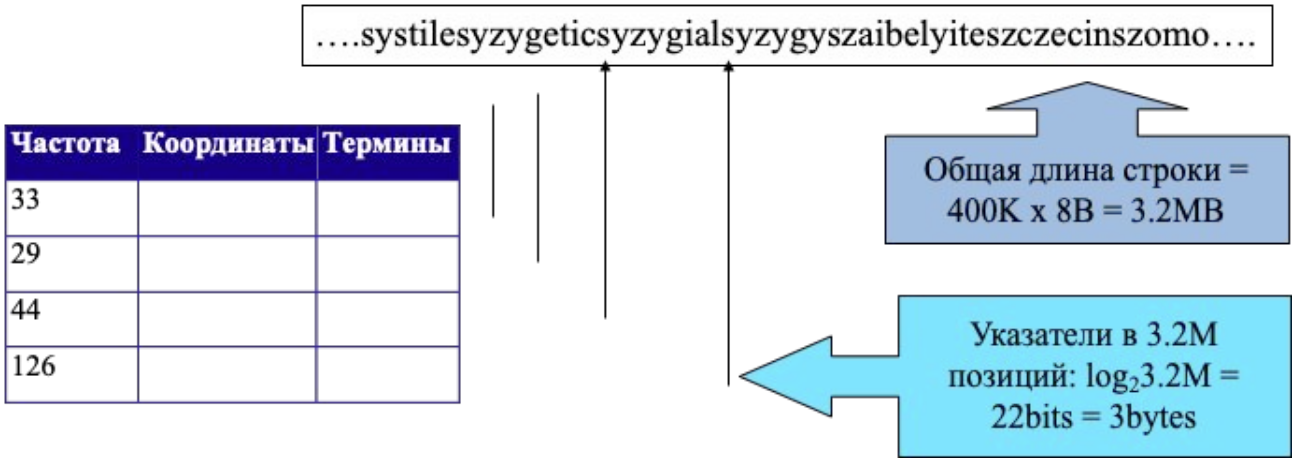

Место для такого словаря

- 4 байта на частоту.
- 4 байта на указатель на Kb.
- 3 байта на указатель на термин
- 8 байтов на термин в строке
- 400K терминов x 19 ⇒ 7.6 MB (против 11.2 Mb для фиксированной длины)

Объединяем в блоки

- Храним указатели на каждый k-ый термин
- В примере: k=4.
- Нужно хранить длины терминов (+1 байт)

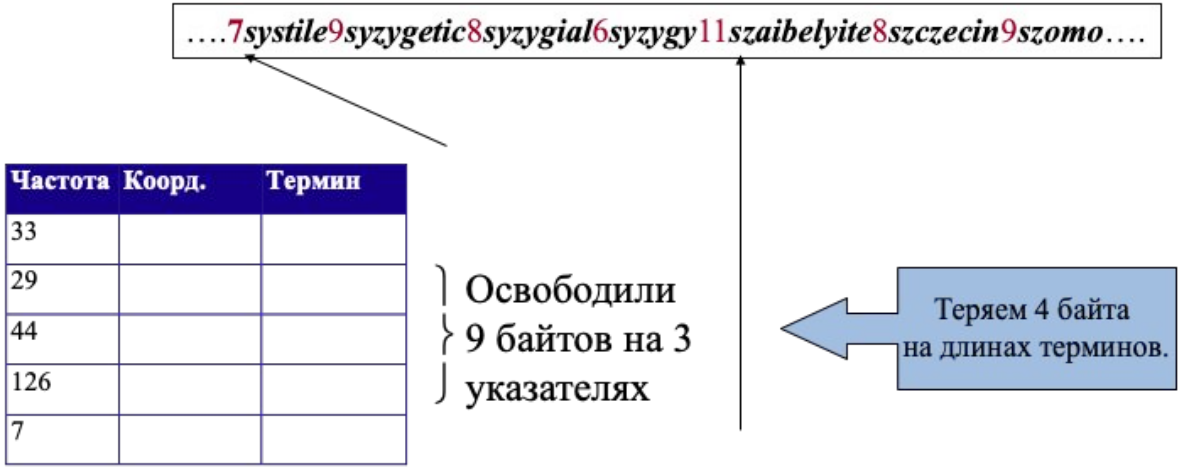

В итоге

- Для размера блока k = 4
- Раньше тратили 3 байта на указатель
- 3 x 4 = 12 байтов,
- теперь тратим 3 + 4 = 7 байтов.

Убрали ~0.5 Mb и уменьшили словарь с 7.6 Mb до 7.1 Mb.

Можем попробовать взять большие k.

Почему нет?

Поиск по дереву без блоков

- Если количество доступ к каждому термину равновероятен (на практике это не так), то среднее количество сравнений будет = (1+2·2+4·3+4)/8 ~2.6
- Если поиск терминов не равновероятен, то как могла бы выглядеть структура данных, учитывающая эту информацию?

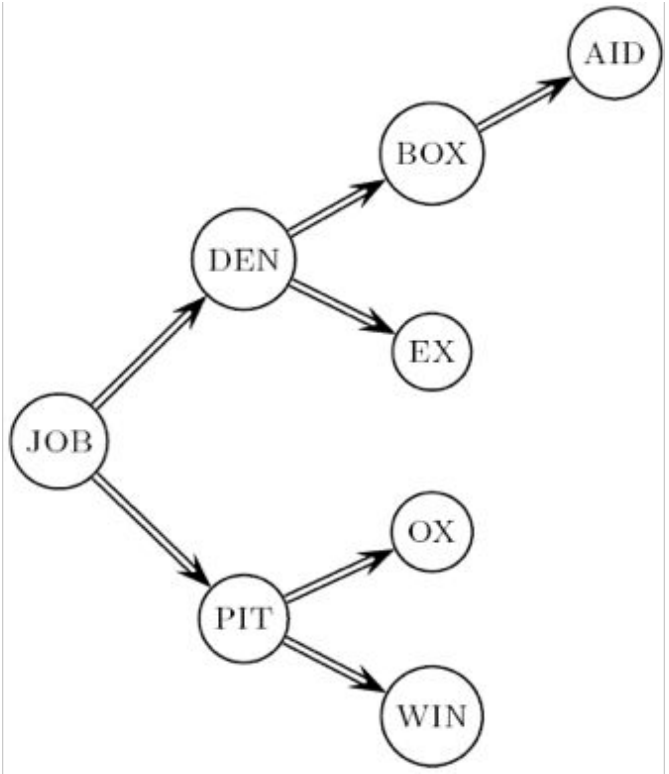

Поиск по дереву с блоками

- Поиск в дереве доходит до блока с 4-я терминами;
- Далее – линейный поиск внутри блока.
- Теперь среднее =

  (1+2·2+2·3+2·4+5)/8 = 3 сравнения

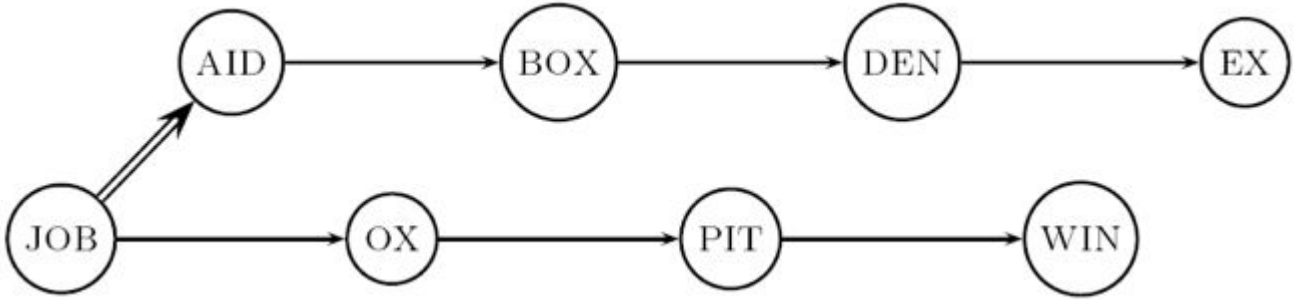

Префиксное сжатие

- Префиксное сжатие:
- Рядом стоящие слова в отсортированной последовательности обычно имеют длинный общий префикс - будем хранить его отдельно
- 8automata8automate9automatic10automation

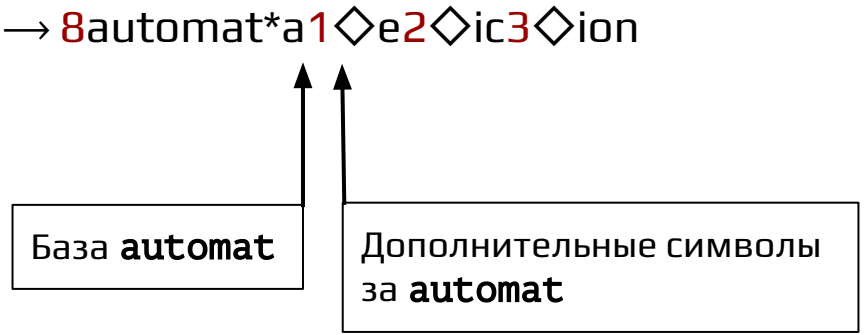

Сжатие словаря для RCV1

Метод	Размер (Mb)
Фиксированная ширина	11.2
Словарь как строка	7.6
+ блоки $k = 4$	7.1
+ префиксное сжатие	5.9

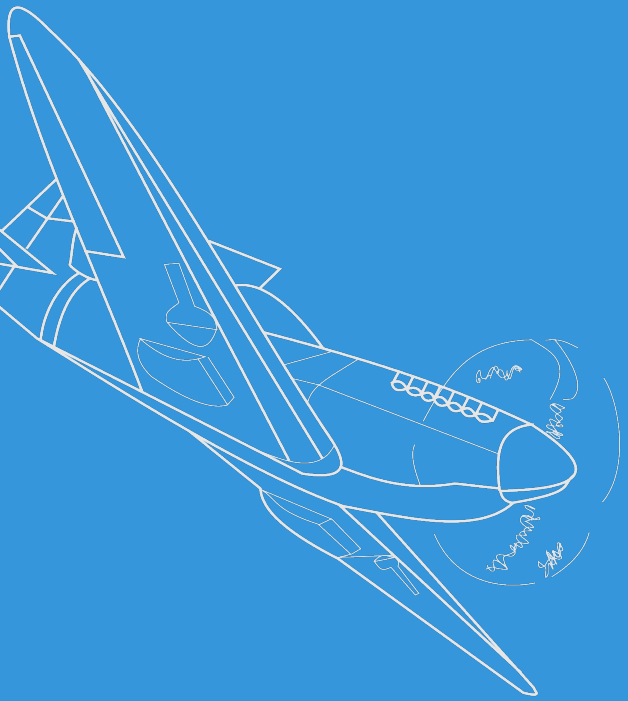

Сжатие координатных блоков

Сжатие координатных блоков

- Координатные блоки значительно больше словаря (для булевского поиска – в 10 раз)
- Будем сжимать каждый постинг.
- В булевском индексе – это docID.
- Для Reuters (800,000 документов), мы можем использовать 32 бита на docID – 4-х байтовые целые.
- Или мы можем взять $\log_2$ 800,000 ≈ 20 битов на docID.
- Наша задача: значительно меньше, чем 20 битов.

Два противоположных случая

- Термин *параскаведекатриафобия* встречается в одном документе на миллион – потребуется $\log_2 1M \sim 20$ бит и это нам подходит.
- Термин же и встречается практически везде, 20 битов слишком много.
  - Лучше битмап.
  - А может быть и RLE.

Координаты

- Список документов хранится в порядке возрастания DocID.
  - computer: 33,47,154,159,202 …
- Следовательно: можем хранить промежутки.
  - 33,14,107,5,43 …
- Надеемся: промежутки потребуют меньше, чем 20 бит.

Примеры координатных блоков

	encoding	postings list									
THE	docIDs	...		283042		283043		283044		283045	...
	gaps				1		1		1		...
COMPUTER	docIDs	...		283047		283154		283159		283202	...
	gaps				107		5		43		...
ARACHNOCENTRIC	docIDs	252000		500100							
	gaps	252000	248100								

Кодирование с переменной длиной

- Цель:
  - Для [**параскаведекатриафобия**], использовать ~20 бит на промежуток.
  - Для [**и**], использовать ~1 бит на промежуток.
- Если средний промежуток размера G, мы хотим использовать ~$\log_2 G$ битов на промежуток.
- Главное: кодировать каждое целое число минимальным количеством битов.
- Требуется код с переменной длиной.
- Будем достигать желаемого тем, что будем назначать короткие коды небольшим промежуткам.

Код Variable Byte (VB)

- Для G, мы хотим тратить как можно меньше байт, достаточных для хранения $\log_2 G$ бит
- Выделим в каждом байте один бит под служебные цели, c (есть продолжение или нет)
- Если G ≤127, кодируем его в 7 бит и c = 1
- Иначе кодируем младшие 7 бит и используем дополнительные байты для хранения остатка по тому же алгоритму
- У последнего байта c = 1, всех остальных – c = 0.

Пример

docIDs	824	829	215406
gaps		5	214577
VB code	00000110 10111000	10000101	00001101 00001100 10110001

Координаты хранятся конкатенированной строкой

000001101011100010000101000011010000110010110001

Ключевое свойство: VB-код является префиксным

Для маленького промежутка (5), VB тратит целый байт.

Другие коды переменной длины

- Вместо байта можно использовать другие границы выравнивания: 32, 16, 4 бита.
- Меньшая граница выравнивания позволяет не терять биты на мелких промежутках – полезно, если много мелких промежутков.
- Коды переменной длины:
- Часто используется
- Хорошо ложатся на архитектуру ЭВМ.
- Можно так же упаковывать несколько промежутков в одно слово.

Унарный код

- Представим n как n единиц с заключительным нулём.
- Унарный код для 3 – 1110.
- Унарный код для 40:
- 11111111111111111111111111111111111110 .
- Унарный код для 80:
- 11111111111111111111111111111111111111111111111111111111111111111111111110
- Не кажется многообещающим, однако….

Гамма-код

- Можем сжимать лучше на уровне битов
  - Гамма-код – самый известный среди них.
- Представим промежуток G в виде пары длина и смещение
- смещение это G в бинарном коде, без ведущей единицы
  - Например, 13 → 1101 → 101
- длина – количество битов в смещении
  - Для 13 (смещение 101), это 3.
- Кодируем длину унарным кодом: 1110.
- Гамма код числа 13 – конкатенация длины и смещения: 1110101

Примеры гамма-кодов

число	длина	смещение	γ-код
0			none
1	0		0
2	10	0	10,0
3	10	1	10,1
4	110	00	110,00
9	1110	001	1110,001
13	1110	101	1110,101
24	11110	1000	11110,1000
511	111111110	11111111	111111110,11111111
1025	11111111110	0000000001	11111111110,0000000001

Гамма-код

- G кодируется 2 log G + 1 битами
- Размер смещения: log G битов
- Размер длины: log G + 1 битов
- Все гамма коды имеют нечётное количество битов
- В два раза хуже лучшего результата, $\log_2 G$

- Гамма коды – префиксные коды, как и VB
- Могут использоваться для любого распределения чисел.
- Не требует параметров.

Редко используется на практике

- Нужно учитывать границы машинных слов – 8, 16, 32, 64 бит
  - Операции, затрагивающие границы машинных слов, значительно медленнее.
- Работа с битами может быть медленной.
- VB кодировка выровнена по границам машинных слов и потенциально более быстрая.
- VB значительно проще в реализации.

Сжатие RCV1

Структура данных	Размер в MiB
словарь, фиксированная ширина	11.2
словарь, термины в одной строке	7.6
блоки, k = 4	7.1
блоки и префиксное сжатие	5.9
корпус (текст, разметка и т.п.)	3,600.0
корпус (текст)	960.0
матрица термины-документы	40,000.0
координатные блоки, несжатые (32 битные слова)	400.0
КБ, несжатые (20 битов)	250.0
КБ, VB-код	116.0
КБ, g-код	101.0

Подводим итоги

- Теперь мы можем создать небольшой индекс для булевского поиска
- Всего 4% от общего размера корпуса
- 10-15% от размера текста корпуса
- Но мы не хранили координатную информацию
- Т.е. в реальности индексы больше размером
  - Но методы сжатия похожи на рассмотренные.
- Рассмотрим ещё несколько алгоритмов

Rice

- Рассмотрим среднее кодируемых чисел, g
- Округлим g до ближайшей степени 2
- Каждое число x будем представлять как
  - (x-1)/b в унарном коде
  - (x-1) mod b в бинарном коде

Пример:

- DocID: 34, 178, 291, 453
- Промежутки: 34, 144, 113, 162
- Среднее: g = (34+144+113+162)/4 = 113,33
- Округляем: b = 64 (6 бит)
- Теперь:
  - 33 = 0*64 + 33 = 0 100001
  - 143 = 2*64 + 15 = 110 001111
  - 112 = 1*64 + 48 = 10 110000
  - 161 = 2*64 + 33 = 110 100001

Golomb

- Похож на Rice
- b подбирается по распределению
- Часто подходит b = 0,69*g (не степень 2-ки!)
- Мотивация – в Managing Gigabytes
- Кодирование аналогично Rice
- Но нужно использовать разное количество бит в представлении (x-1) mod b
- Хорошо подходит для случайных промежутков

Пример:

- DocID: 34, 178, 291, 453
- Промежутки: 34, 144, 113, 162
- Среднее: g = (34+144+113+162)/4 = 113,33
- Округляем: b = 0,69*g = 78 (6 или 7 бит)
- (x-1) mod b < 50: 6 бит, иначе – 7 бит
  - (78-50)/2 = 14, 50+14 = 64, т.е. значения между 50 и 64 указывают на дополнительный бит
- Теперь:
  - 33 = 0*78 + 33 = 0 100001
  - 50 = 0*78 + 50 = 0 1100100
  - 64 = 0*78 + 64 = 0 1100101
  - 143 = 1*78 + 65 = 10 1100111
  - 112 = 1*78 + 34 = 10 100010
  - 161 = 2*78 + 5 = 110 000101

Свойства кодов Rice и Golomb

- Параметризуются b
  - Глобально – для всего корпуса
  - Локально – для термина
    - Можно не хранить: $g = (N - f_t) / (f_t + 1)$
- Однако не могут настроиться на кластеры вхождений в координатных блоках
- Можно рассчитывать b не для термина, а для блока рядом стоящих документов
- Лучше сжимают, но медленнее VB

Simple9

- Нужен код, выровненный по словам
  - 32 бита
- Разобьём слово на две части: 4 бита под управление и 28 бит под данные
- Что можно сохранить в 28-и битах?
  - 1 28-и битное число
  - 2 14-и битных числа
  - 3 9-и битных числа (и теряем 1 бит)
  - 4 7-и битных числа
  - 5 5-и битных чисел (и теряем 3 бита)
  - 7 4-х битных чисел
  - 9 3-х битных чисел (и теряем 1 бит)
  - 14 2-х битных чисел
  - 28 1 битных чисел
- И запишем в 4 управляющих бита используемую схему
  - И ещё могут быть исключения, число больше 28 бит

Свойства Simple9

- Просто упаковать
  - Следующие 28 чисел помещаются в 1 бит?
    - Если нет, то 14 в два бита?
      - И т.д.
- Быстро распаковать (один if на слово)
- Хорошо сжимает
- Есть варианты, например, Simple16

PFOR-DELTA

- Будем сжимать сразу много значений, например, 128
- Сколько выделить бит?
  - Выбирать под каждое значение? – Много ветвлений, медленно.
  - Выбрать одно для всех? – Плохо сжимается.
- Идём на компромисс: подберём одно значение для 90% чисел, остальные – исключения

Пример

- 90% чисел < 32, возьмём b = 5
- Размер блока = 5*128 бит + место под исключения
- Исключения храним в хвосте, числами без кода (4 байта на каждое)
- 23, 41, 8, 12, 30, 68, 18, 45, 21, 9, ...

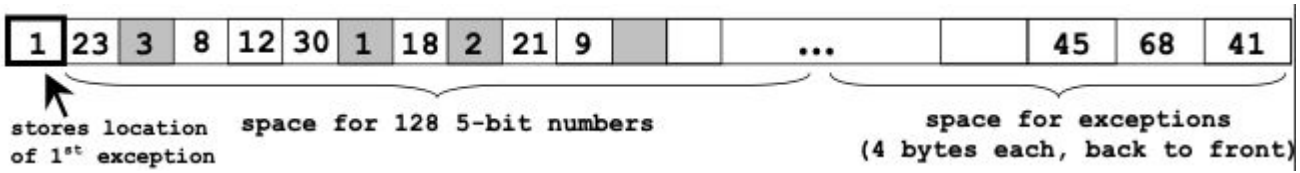

Свойства

- Могут быть псевдо-исключения
  - Если встретилось подряд больше чем 2b чисел < 2b
- Простая реализация и быстрая декомпрессия
- Всегда распаковываем 128 чисел во временный массив
- Можно немного улучшить за счёт отдельной схемы сжатия под исключения
  - Просто за счёт уменьшения 32 бит до максимальной битности можно получить 10-20% улучшения сжатия

Сравнение алгоритмов - размер

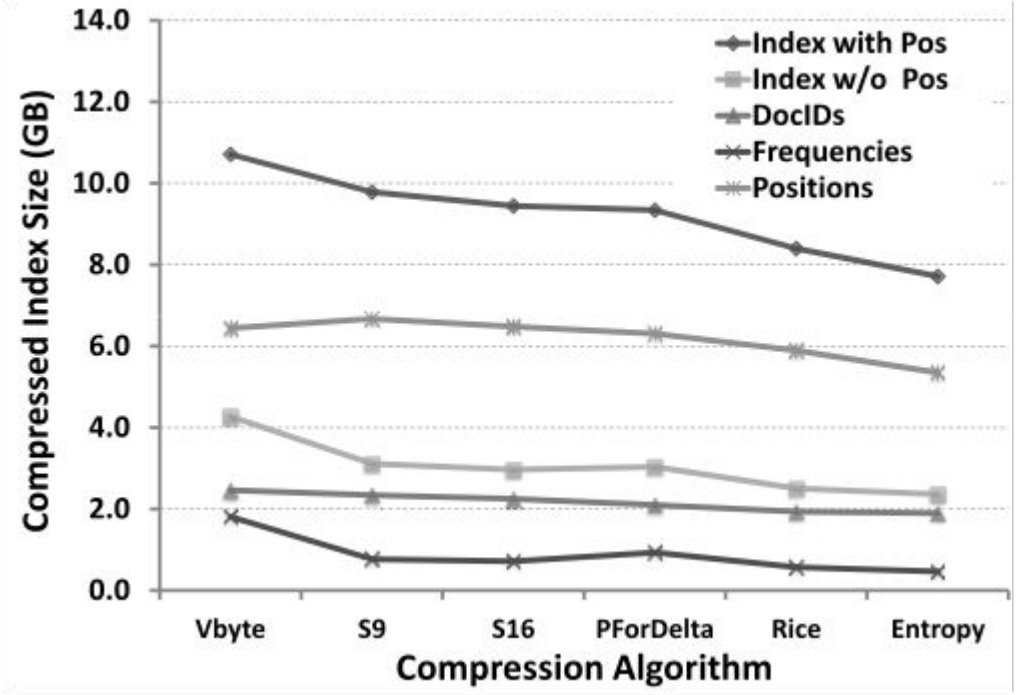

Байтов на число

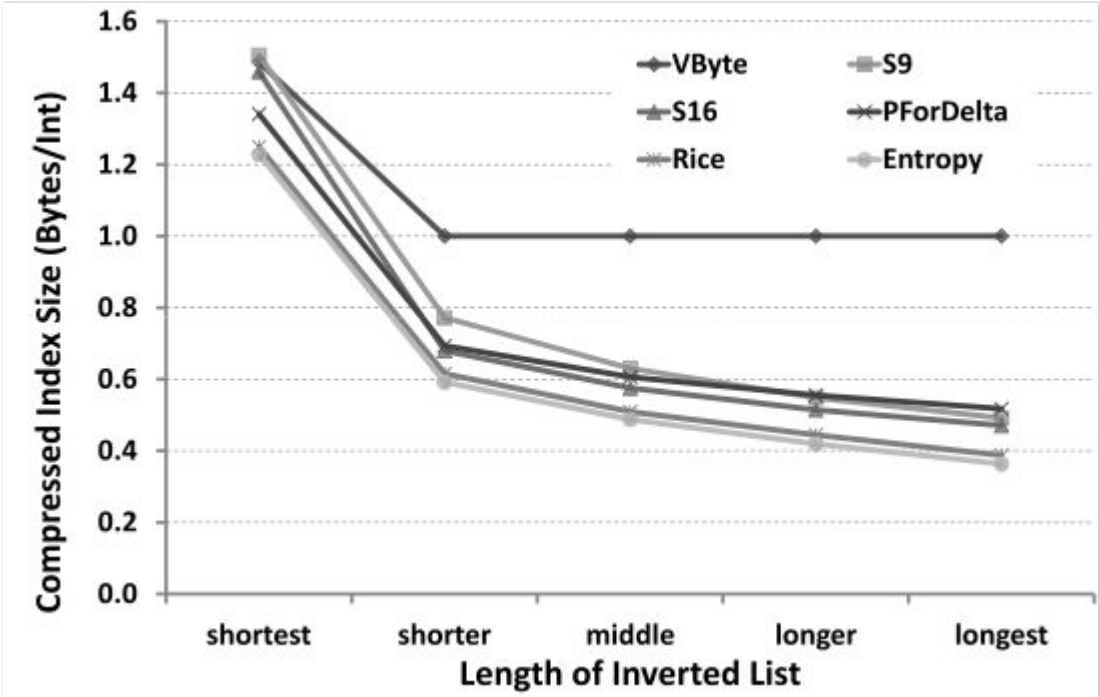

Декомпрессия всего индекса

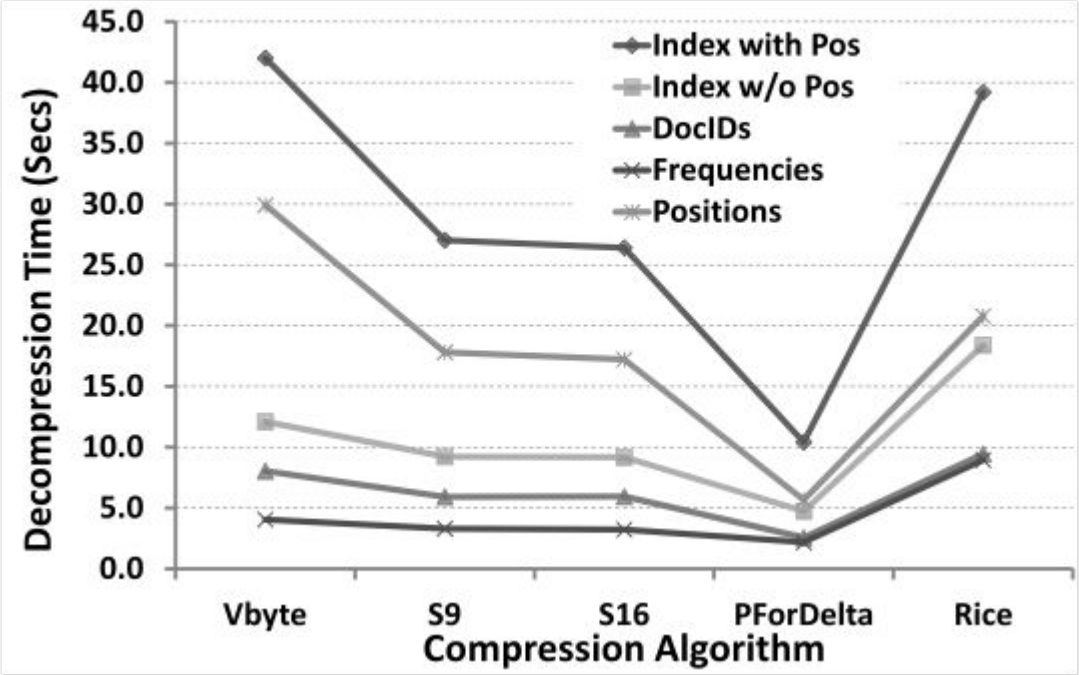

Декомпрессия «на запрос» (CPU)

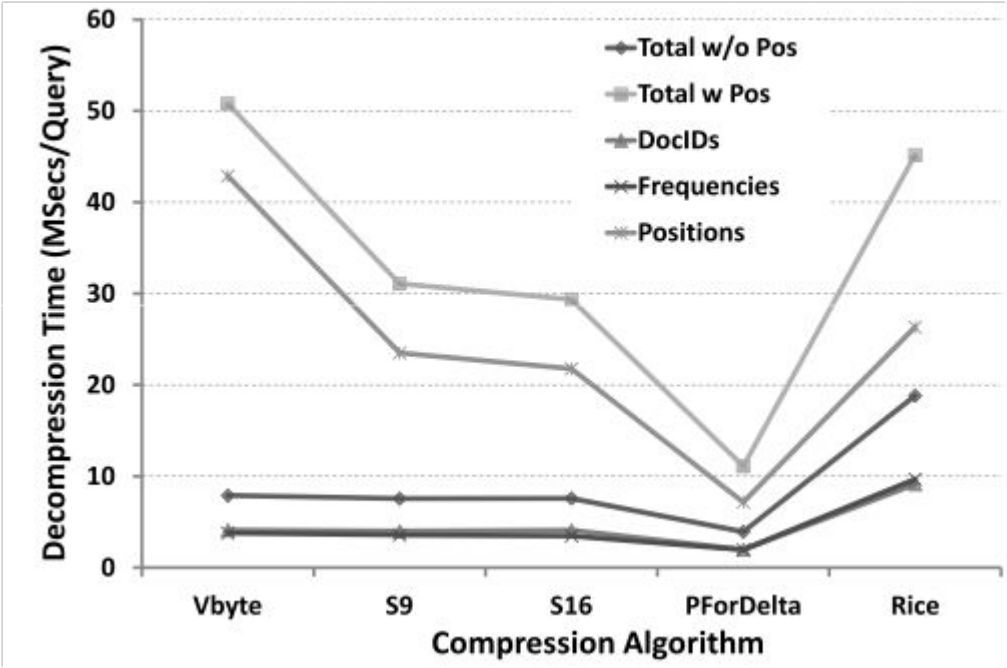

Сравнительная скорость распаковки

- Миллионы целых чисел в секунду:

Algorithm	Total w/o Pos	Total w Pos	DocID	Freq	Pos
VByte	441.99	174.55	424.68	460.78	125.26
S9	461.36	285.13	437.29	488.25	228.39
S16	460.75	301.91	425.47	502.41	246.62
PForDelta	889.14	798.38	889.69	888.59	748.68
Rice	185.60	196.30	191.23	180.30	203.95

Оптимальное расположение документов

- Блочная компрессия работает лучше, если похожие документы располагаются рядом
- Удобно использовать вместе с системой поиска дубликатов
- Для веба есть простая эвристика: номера docid должны соответствовать отсортированному в лексикографическом порядке списке URL.

Что ещё можно почитать

- IIR 5
- MG 3.3, 3.4.
- F. Scholer, H.E. Williams and J. Zobel. 2002. Compression of Inverted Indexes For Fast Query Evaluation. Proc. ACM-SIGIR 2002.
  - Variable byte codes
- V. N. Anh and A. Moffat. 2005. Inverted Index Compression Using Word-Aligned Binary Codes. Information Retrieval 8: 151–166.
  - Word aligned codes

Рекомендуемая литература

[Введение в информационный поиск | Маннинг Кристофер Д., Шютце Хайнрих]

Для саморазвития (опционально)

[Чтобы не набирать двумя пальчиками]

Спасибо за внимание!

Антон Кухтичев

a.kukhtichev@mail.ru

@toshunster