МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ

Урок №9

Текстовое ранжирование. Часть II. Сводим всё воедино

(основано на слайдах Андрея Калинина, Hinrich Schütze, Christina Lioma)

25 ноября 2021 года

Антон Кухтичев

Содержание занятия

1. Ускоряем векторное ранжирование
2. Строим полноценную поисковую систему
    a. Потребуется некоторое количество ухищрений и эвристик

Вычисление весов-косинусов


```
CosineScore(q)
 1  float Scores[N] = 0
 2  float Length[N]
 3  for each query term t
 4  do calculate w_{t,q} and fetch postings list for t
 5      for each pair(d, tf_{t,d}) in postings list
 6      do Scores[d] += w_{t,d} × w_{t,q}
 7  Read the array Length
 8  for each d
 9  do Scores[d] = Scores[d]/Length[d]
10  return Top K components of Scores[]
```

Оптимизация вычислений

- Нужно найти K «ближайших» к запросу документов ⇒ *k* самых больших косинусов между запросом и документом.
- Оптимизация ранжирования:
  - Быстрое вычисление одного косинуса.
  - Быстрый выбор *k* наибольших косинусов.
    - Можно ли при этом не вычислять все N косинусов?

Оптимизация вычислений

- Что мы делаем: решаем задачу поиска k-ближайших соседей для вектора запроса
- Вообще, мы не знаем, как эффективно решать эту задачу для пространств большой размерности.
- Но есть методы для коротких запросов, совместимые с обычными индексами.

Особый случай – запросы без весов

- Не будем взвешивать термины запроса
  - Предположим, что каждый термин в запросе встречается только один раз
- Тогда не требуется нормализация запроса
  - Небольшое упрощение алгоритма из 7-й лекции

Ускоряем: запрос без взвешивания

FastCosineScore(q)

```
1   float Scores[N] = 0
2   for each d
3   do Initialize Length[d] to the length of doc d
4   for each query term t
5   do calculate w_{t,q} and fetch postings list for t
6       for each pair(d, tf_{t,d}) in postings list
7       do add wf_{t,d} to Scores[d]
8   Read the array Length[d]
9   for each d
10  do Divide Scores[d] by Length[d]
11  return Top K components of Scores[]
```

Figure 7.1 A faster algorithm for vector space scores.

Вычисление *k* наибольших косинусов: выбор или сортировка?

- Обычно мы хотим получить только *k* верхних документов
  - а не отсортировать все документы в корпусе
- Можем ли мы выбрать K документов с наибольшими значениями косинусов?
- Пусть J = количество документов с ненулевыми косинусами
  - Мы ищем *k* лучших из J документов

Используем кучу для выбора K максимальных

- Бинарное дерево, где значение в каждой вершине больше значений детей
- Требует 2J операций для создания, затем каждый документ из K-верхушки добывается за 2log J шагов.
- Для J = 1M, K = 100, это где-то 10% от стоимости сортировки.

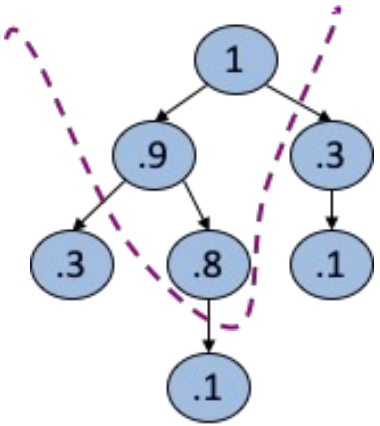

Узкие места

- Главная вычислительная проблема во взвешивании – вычисление косинусов.
- Можно ли избежать этих вычислений?
- Да, но иногда недостаточно точно
  - документ не из K-верхушки может пролезть в окончательный список K документов
  - Действительно ли это так страшно?

Косинусы лишь приближение

- У пользователя есть задача и он сформулировал запрос
- Косинусы позволяют найти документы для этого запроса
- Косинус – приближение удовлетворённости пользователя
- Если мы получим список K документов, достаточно близкий к K-верхушке «по косинусам», то всё должно быть в порядке

Общий подход

- Найдём множество A соискателей такое, что

  K < |A| << N

  - A может не содержать все документы из верхушки K, но должно иметь достаточное количество
  - Вернём верхние K документов из A
- Английский термин – pruning
- Аналогичный подход используется и для других функций взвешивания
- Рассмотрим несколько реализаций этого подхода

Убираем ненужные документы

- Базовый алгоритм FastCosineScore рассматривает только документы, содержащие хотя бы один термин запроса
- Пойдём дальше:
  - Будем рассматривать только термины с высокими значениями idf
  - Отсечём документы с небольшим количеством терминов запроса

Термины с большим IDF

- Для запроса [catcher in the rye]
- Будем учитывать веса только для catcher и rye
- Идея: in и the не дают большого вклада в итоговый вес, т.е. не могут сильно повлиять на итоговый результат.
- Выгода:
  - Координатные блоки терминов с небольшим IDF будут иметь много документов → они пропадут из списка A

Документы с большим количеством терминов из запроса

- Любой документ, содержащий хотя бы один термин из запроса, является кандидатом для результирующего списка
- Для длинных запросов будем отбирать документы, содержащие несколько терминов запроса
  - Например, 3 из 4-х
  - «Мягкая коньюнкция» веб-поиска
- Просто реализовать при проходе по координатным блокам

3 из 4-х терминов

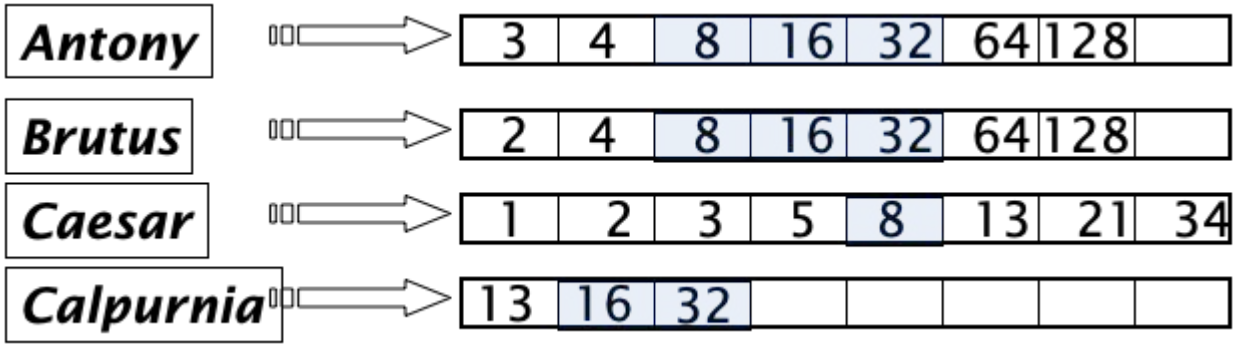

- Веса вычисляются для документов 8, 16 и 32.

Лучшие документы

- Предвычислим для каждого термина t r документов с самыми высокими весами среди координат t
  - Английское название: champion list
  - (или fancy list)
- Значение r выбирается при построении индекса
  - Можно выбрать r < K
- При выполнении запроса вычисляем веса только для лучших документов какого-то из терминов запроса

Вопросы

- Можно ли использовать списки лучших документов с уже рассмотренными способами? Есть ли в этом необходимость?
- Как эти списки могут быть реализованы в обратном индексе?
  - Списки лучших никак не соотносятся с docID

Статические веса

- Мы хотим, чтобы документы наверху выдачи были бы релевантными и авторитетными
- Релевантность сейчас оценивается косинусами
- Авторитетность не зависит от запроса
- Примеры авторитетных документов:
  - Википедия среди веб-сайтов
  - Статьи в некоторых газетах или информационных агентствах
  - Научная статья с большим количеством ссылок на неё
  - Много социальных «рекомендаций», упоминаний в твиттерах и т.п.
  - Pagerank

Модель авторитетности

- Назначим каждому документу d запросо-независимый вес качества из диапазона [0,1]
  - Обозначим его как g(d)
- Например, количество ссылок нормированное в [0,1]
  - Вопрос: по какой формуле?

Общий вес

- Рассмотрим простой вес, учитывающий релевантности «по косинусам» и авторитетность
- net-score(q,d) = g(d) + cosine(q,d)
  - Можем использовать другую линейную комбинацию
  - Или любую функцию от двух факторов (сигналов), моделирующую удовлетворённость или счастье пользователя
- Теперь мы ищем K-верхушку по общему весу

Быстрый способ получить K-верхушку по общему весу

- Идея: упорядочить координаты по g(d)
- Часто так и делают для всех координат
- Можем одновременно проходить термины запроса для
  - Пересечения координат
  - Вычислению веса «по косинусам»
- Упражнение: Напишите псевдокод

Зачем упорядочивать по g(d)?

- В этом случае документы с большими весами имеют высокую вероятность оказаться в начале списков
- При ограничениях на время выполнения мы можем остановить время выполнения по достижению лимита времени или количества найденных документов
  - Тем самым, не считаем косинусы для всех документов из координатных блоков

Списки лучших документов и упорядочение по авторитетности

- Можно объединить два подхода
- Подготовим для каждого термина список лучших документов с высшими значениями $g(d) + tf\text{-}idf_{td}$
- Найдём верхние K результатов среди документов из этих списков

Эшелоны

- Для каждого термина построим два координатных блока, «золотой» и «серебряный»
  - Золотой – список лучших документов
- При обработке терминов запроса сначала проходим только по золотым блокам
  - Если в результате получим больше K документов, то заканчиваем выполнение запроса
  - Иначе переходим к серебряным блокам
- Можно использовать и без g(d)
- Тем самым, делим индекс на два эшелона

Упорядочение координат по весам

- Мы можем вычислить веса только для тех документов, где $wf_{t,d}$ достаточно высок
- Сортируем все координаты по $wf_{t,d}$
- Но теперь: все координаты в расположены в разном порядке!
- Как вычислить веса для выбора K-верхушки?
  - Есть пара идей

1. Раннее прекращение запроса

- При обходе координат t, остановим выполнение запроса как только
  - Обработали или получили r документов
  - $wf_{t,d}$ стал меньше некоторого порога
- Объединим все документы для каждого термина
- Вычислим веса только для этого набора документов

2. Термины в IDF-порядке

- При обработке координат для терминов…
- … будем загружать их в порядке убывания IDF
  - Термины с высоким IDF дадут больший вклад в итоговый вес
- При обновлении весов для терминов остановимся тогда, когда веса перестают значимо меняться
- Применимо не только для «косинусов»

Кластеризация индекса: подготовка

- Выберем случайны √N документов: *лидеры*
- Для остальных документов найдём ближайшего лидера
  - Документы, отнесённые к лидеру – его *последователи*;
  - Вероятно: каждый лидер будет иметь

    ~ √N последователей.

Кластеризация: выполнение запроса

- Выполняем запрос так:
  - Для запроса Q найдём ближайшего *лидера* L.
  - Затем найдём K ближайших документов среди последователей L.

Примерно так:

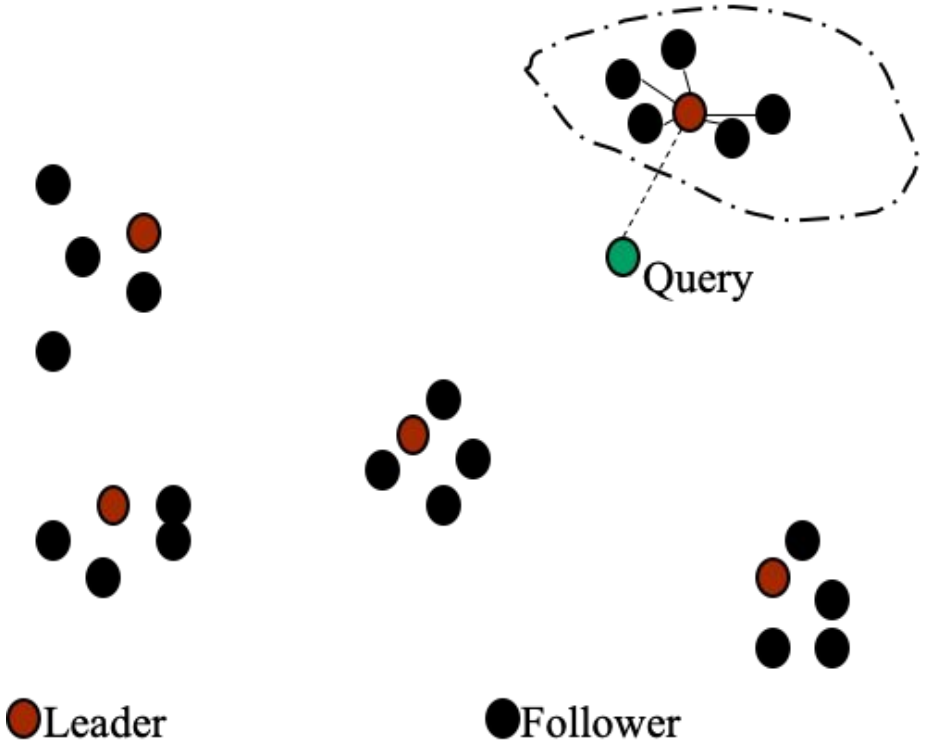

Почему случайный выбор?

- Быстро
- Лидеры отражают распределение данных в корпусе

Вариации

- Каждый последователь присоединяется к, например, b1=3 ближайшим лидерам.
- Для запроса найдём, например, b2=4 ближайших лидеров и их последователей.

Упражнения

- Сколько нужно вычислить косинусов, чтобы найти ближайшего лидера на шаге 1?
  - Откуда взялось число √N?
- Каков эффект от констант b1, b2 с предыдущего слайда?
- Приведите пример, когда этот подход скорее всего будет неудачным – т.е., мы пропустим один из K документов.
  - Скорее всего – при условии случайного выбора лидеров.

Параметрические индексы и зоны

- До сих пор документ представлялся последовательностью терминов
- Обычно документы состоят из нескольких частей, с определённой семантикой:
  - Автор
  - Заголовок
  - Дата публикации
  - Язык
  - Формат
  - И т.п.
- Всё это – метаданные

маёвник

Поля (числовые зоны)

- Иногда мы хотим искать в метаданных
  - Например, найти документа за авторством Шекспира, написанные в 1601-м году и содержащие цитату alas poor Yorick

YEAR*1601

- Year = 1601 это пример поля
- Так же, author last name = shakespeare и т.п.
- Для хранения этих данных строится специальный индекс (параметрический): координаты для каждого значения поля
  - Иногда более сложные структуры, например для диапазонов
- Запросы к полям обычно коньюктивные
  - (документ должен быть за авторством shakespeare)

Зоны документа

- Зона это часть документа, содержащая какой-то особенный текст, например,
  - Заголовок
  - Описание
  - Ссылки …
- Для зон так же строится обратный индекс
- Теперь можно выполнять запросы вида «найди документы с merchant в заголовке и удовлетворяющие запросу gentle rain”

Индексы для зон

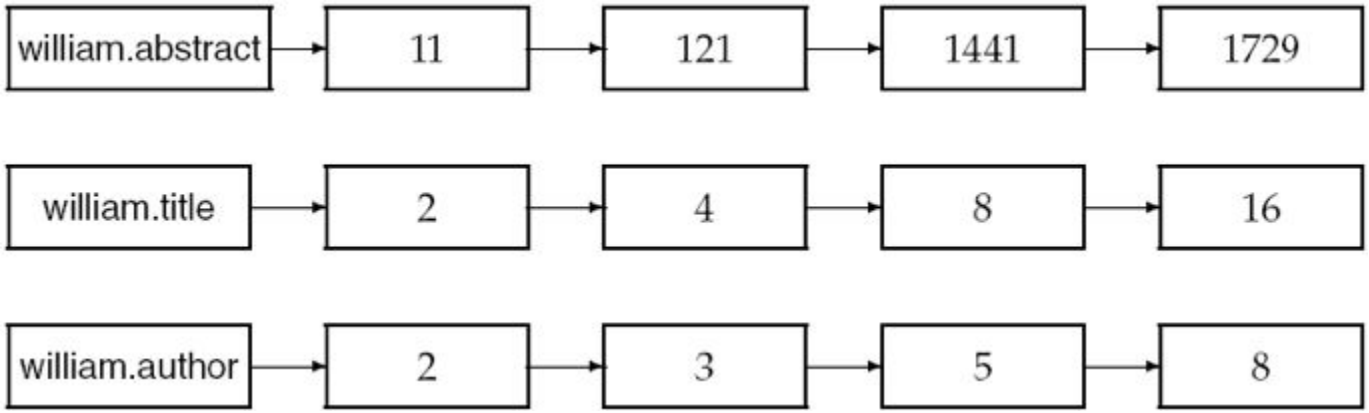

Можно хранить зоны в словаре или в координатах

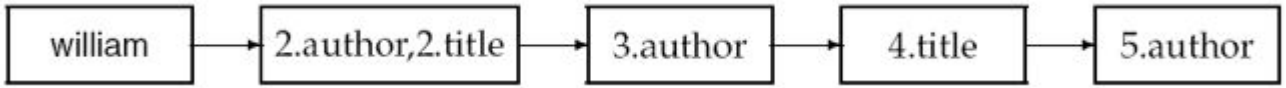

Эшелонированные индексы

- Делим координаты по их важности
  - Самые важные
  - …
  - Менее важные
- Можем оценивать по g(d)
- Тем самым индекс поделён на эшелоны по убыванию важности
- Во время выполнения запроса берём первый эшелон, если в нём получилось найти K документов
  - Иначе переходим к следующим эшелонам

Пример эшелонирования

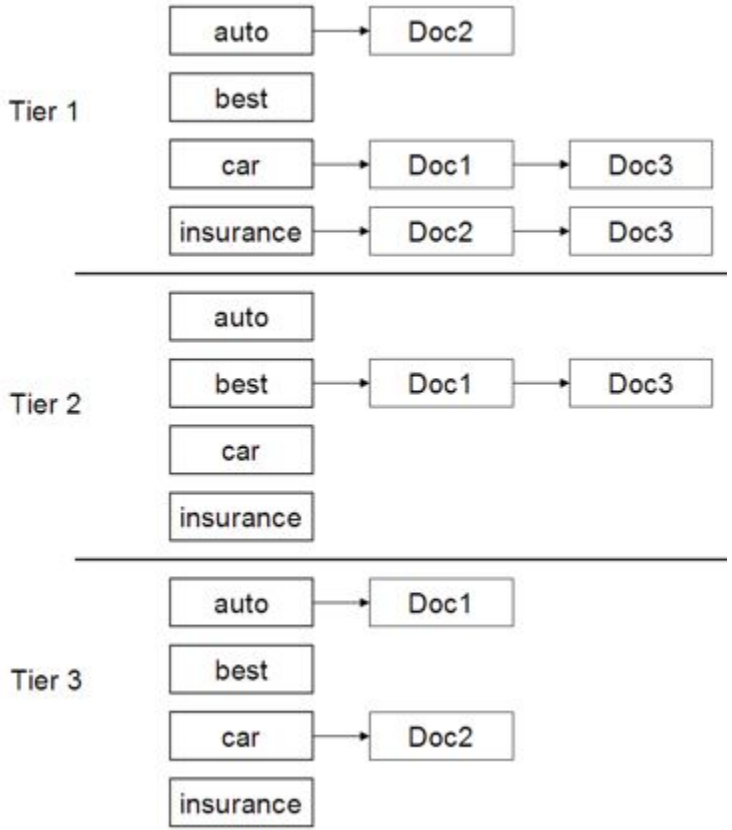

Компактность вхождения

- Текстовые запросы: набор терминов, введённых в поисковую строчку
- Пользователи предпочитают документы, где термины запроса находятся на небольшом расстоянии друг относительно друга
- Пусть w будет наименьшим окном в документе, содержащим все термины запроса. Например,
- Для запроса [strained mercy] такое окно в документе The quality of mercy is not strained равно 4 (в словах)
- Хотим включить это в итоговый вес – как?

Парсер запроса

- Парсер запроса может подготовить по одному запросу несколько фактических запросов к индексу, например rising interest rates
  - Обработать как цитатный
  - Если нашли <K документов с цитатой rising interest rates, обработать как два цитатных запроса rising interest и interest rates
  - Если всё ещё <K документов, обработать как векторный запрос rising interest rates
  - Отсортировать документы по весу в векторном пространстве
- Такую последовательность операций может сгенерировать парсер запроса.

Объединение весов

- Мы уже построили функции весов, объединяющие в себе косинусы, авторитетность, компактность и т.п.
- Как найти лучшую такую функцию?
- Иногда – вручную
- В последнее время – машинное обучение
  - Ещё поговорим об этом (а может и нет)

Соединяем всё вместе

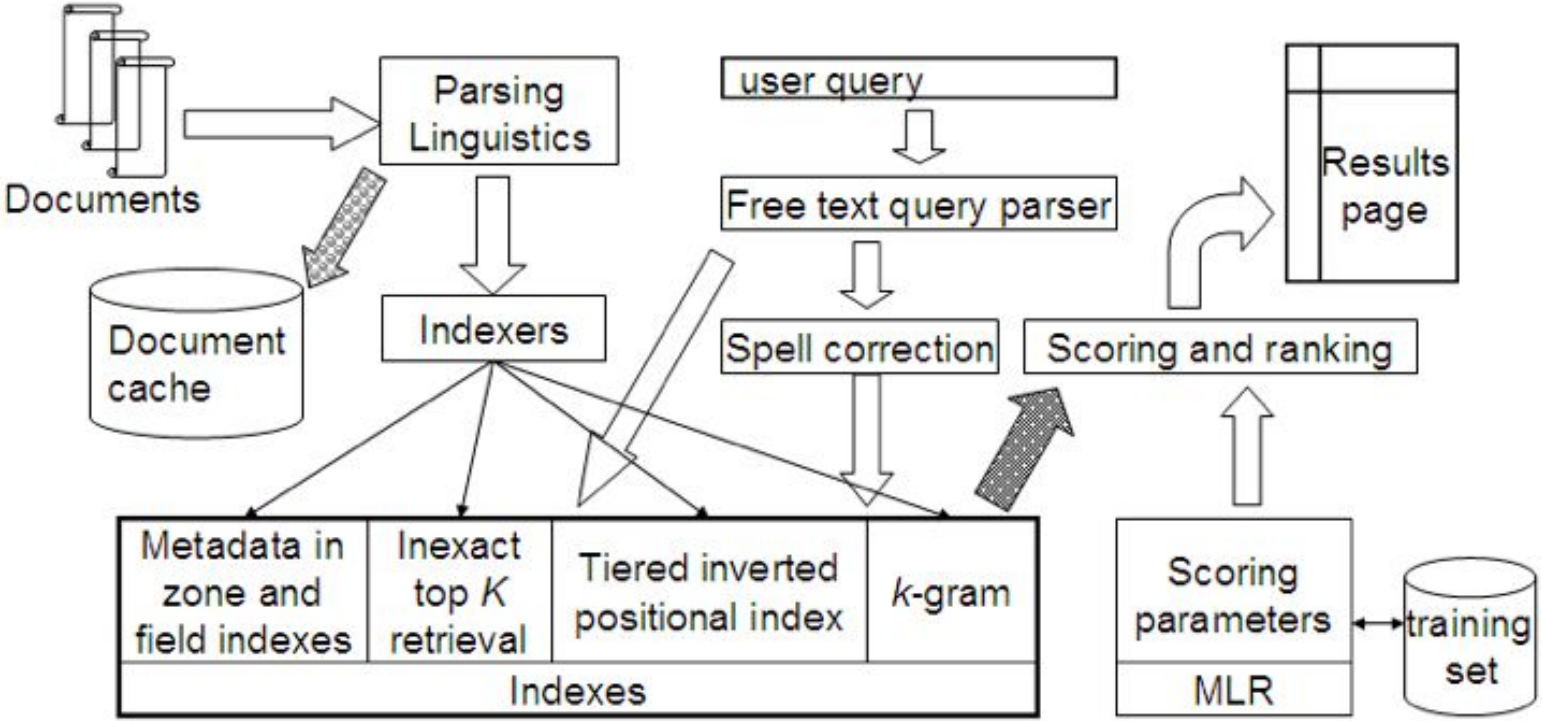

Рекомендуемая литература

[Введение в информационный поиск | Маннинг Кристофер Д., Шютце Хайнрих]

Для саморазвития (опционально)

[Чтобы не набирать двумя пальчиками]

Спасибо за внимание!

Антон Кухтичев

a.kukhtichev@mail.ru

@toshunster